

SAS. Анализ данных в бизнесе

Домашнее задание №1

Выполнила: студентка группы БСТ192 Топникова Варвара

Вариант 19

Структура работы:

- Описание данных. Введение
- Часть 1: Исследование данных. Подготовка данных для сегментации
- Часть 2: Сегментация

ОПИСАНИЕ ДАННЫХ. ВВЕДЕНИЕ

Изначальные данные + первоначальная загрузка в систему SAS

Представлены:

- Тестовые данные по клиентам банка, которые имеют кредит

Данные состоят из:

- ВСЕГО 43 переменных , которые будут включены в анализ
- 44-ю переменную – вариант, мы можем удалить, поскольку она точно никак не коррелирует с остальными
- Определение переменных системой SAS:
9 категориальных + 35 количественных
- 10242 строки

▼ Category
📄 CREDIT_PURPOSE - 10
📄 EDUCATION - 10
📄 EMPL_FORM - 7
📄 EMPL_PROPERTY - 13
📄 EMPL_SIZE - 9
📄 EMPL_TYPE - 10
📄 FAMILY_STATUS - 7
📄 INCOME_BASE_TYPE - 5
📄 SEX - 2

▼ Measure
📄 Active_not_cc
📄 Active_to_All_prc
📄 age
📄 all_credits
📄 avg_num_delay
📄 BANKACCOUNT_FLAG
📄 DEPENDANT_NUMBER
📄 dlq_exist
📄 DTI
📄 Frequency
📄 FULL_AGE_CHILD_NUMBER
📄 ID
📄 if_zalog
📄 INSURANCE_FLAG

📄 max_MnthAfterLoan
📄 max14days
📄 max21days
📄 max30days
📄 max60days
📄 max90days
📄 min_MnthAfterLoan
📄 ninety_in_a_year
📄 ninety_vintage
📄 num_AccountActive180
📄 num_AccountActive60
📄 num_AccountActive90
📄 numAccountActiveAll
📄 numAccountClosed
📄 own_closed

📄 Period_at_work
📄 sixty_in_a_year
📄 sixty_vintage
📄 sum_of_paym_months
📄 thirty_in_a_year
📄 thirty_vintage

Python:

Корреляционная матрица

9 категориальных:


- 1) 'INCOME_BASE_TYPE',
- 2) 'CREDIT_PURPOSE',
- 3) 'SEX',
- 4) 'EDUCATION',
- 5) 'EMPL_TYPE',
- 6) 'EMPL_SIZE',
- 7) 'EMPL_PROPERTY',
- 8) 'EMPL_FORM',
- 9) 'FAMILY_STATUS'

+

34 количественных переменных
(сразу удаляем № варианта)

Однако заметим, что некоторые
переменные среди воспринятых
Python и SAS как количественные:
на самом деле являются

КАТЕГОРИАЛЬНЫМИ!



ОПИСАНИЕ ДАННЫХ. ВВЕДЕНИЕ

Корректировка вида переменных (иллюстрация в Excel):

- **Желтые** – категориальные переменные по SAS и Python (9 шт)
- **Синие** – количественные переменные (23 шт)
- **Зеленые** – воспринятые SAS и Python как количественные, но на самом деле категориальные (11 шт)

Итог:

- Общее число категориальных: 20 шт.
- Общее число количественных: 23 шт.

Номер варианта	Номер варианта
ID	Идентификатор клиента
INCOME_BASE_TYPE	Подтверждение дохода
CREDIT_PURPOSE	Цель получения кредита
INSURANCE_FLAG	Страхование заемщика при получении кредита 1/0 = да/нет
DTI	debt-to-income ratio — отношение долга к доходам
SEX	Пол
FULL_AGE_CHILD_NUMBER	Кол-во лет ребенку
DEPENDANT_NUMBER	Кол-во иждивенцев
EDUCATION	Образование
EMPL_TYPE	Должность
EMPL_SIZE	Зарплата
BANKACCOUNT_FLAG	Кол-во аккаунтов у клиента. (0 - нет онлайн -кабинета , 1 - есть один онлайн-кабинет, 2 и более - заходил в онлайн кабинет с другого устройства)
Period_at_work	Время работы (кол-во дней)
age	Возраст
EMPL_PROPERTY	Сфера бизнеса работодателя
EMPL_FORM	Организационно - правовая форма
FAMILY_STATUS	Семейный статус
max90days	кол-во запросов в бюро кредитных историй за последние 90 дней
max60days	кол-во запросов в бюро кредитных историй за последние 60 дней
max30days	кол-во запросов в бюро кредитных историй за последние 30 дней
max21days	кол-во запросов в бюро кредитных историй за последние 21 дней
max14days	кол-во запросов в бюро кредитных историй за последние 14 дней
avg_num_delay	Среднее кол-во задержки оплаты
if_zalog	Наличие залога (квартира,машина) 1/0 = да/нет
num_AccountActive180	кол-во активных счетов счетов за последние 180 дней
num_AccountActive90	кол-во активных счетов счетов за последние 90 дней
num_AccountActive60	кол-во активных счетов счетов за последние 60 дней
Active_to_All_prc	отношение активных счетов ко всем счетам
numAccountActiveAll	кол-во открытых счетов
numAccountClosed	кол-во закрытых счетов
sum_of_paym_months	сумма платежей за последний месяц (тыс.)
all_credits	Кол-во кредитов
Active_not_cc	Активные кредитные счета, но не кредитная карта
own_closed	Кол-во закрытых кредитов
min_MnthAfterLoan	минимальное кол-во месяцев, которое прошло с момента взятия прошлого кредита, то есть как давно выдали последний кредит клиенту
max_MnthAfterLoan	кол-во месяцев прошедшее с момента выдачи первого кредита
dla_exist	наличие просрочки на данный момент 1/0 = да/нет
thirty_in_a_year	просрочка больше 30 дней за последний год 1/0 = да/нет
sixty_in_a_year	просрочка больше 60 дней за последний год 1/0 = да/нет
ninety_in_a_year	просрочка больше 90 дней за последний год 1/0 = да/нет
thirty_vintage	просрочка больше 30 дней, когда-либо 1/0 = да/нет
sixty_vintage	просрочка больше 60 дней, когда-либо 1/0 = да/нет
ninety_vintage	просрочка больше 90 дней, когда-либо 1/0 = да/нет

Часть 1:

Исследование данных.

Подготовка данных для сегментации

Часть 1: Исследование данных. Подготовка данных для сегментации

План работы:

1. Исследование распределения по данным:

- Рассчитываем кол-во уникальных значений, нулевых и пустых значений +доля в % от общего кол-ва;
- Среднее значение, медиана, стандартное отклонение, минимум, максимум,тип данных **по каждому показателю** в предоставленных данных;
- Исследуем распределение данных по полу, возрасту и другим категориальным показателям;

2. Делаем проверку на:

- Полноту данных по клиентам;
- Пропущенные и нулевых значения в полях;
- Наличие некорректных знаков;

3. Готовим итоговую витрину данных для сегментации,

при необходимости:

- Корректируем данные – исправляем ошибки;
- Искключаем клиентов с большим числом пропусков или восстанавливаем пропущенные значения;
- Переводим категориальные показатели в целочисленные;

4. Описываем все пояснения по исследованию данных и по всем преобразованиям данных.

Прежде чем начать исследовать каждую переменную в наших данных, построим корреляционную матрицу. Данная матрица позволит нам проследить степень корреляции между переменными, чтобы понять, можем ли мы их удалять или нет. К сожалению, матрицу мы можем построить только для 23 количественных переменных (но не категориальных).


Python:

Корреляционная матрица

0 категориальных

23 количественных

переменных



Часть 1: Исследование данных. Подготовка данных для сегментации

Сразу бросается в глаза, что преобладает положительная зависимость между количественными переменными.

Корреляция между многими переменными стремится к 1.

Если говорить об отрицательной зависимости, можно заметить, что встречается она сильно реже, а корреляция по модулю не превышает 0,48 (умеренная, но не сильная связь).

Однако практически во всех случаях с высокой корреляцией можно предположить, что это не корреляционная, а прямая арифметическая зависимость.

Однако данная корреляционная матрица описывает только связи между количественными переменными.

Если говорить о связях между категориальными, то актуальнее будет говорить о количестве уникальных, а также нулевых значений.

*Например, наиболее высока (достигает 0,93) корреляция между переменными **max90days**, **max60days**, **max30days**, **max21days** и **max14days**. Данные переменные обозначают количество запросов в бюро кредитных историй за последние N дней. Следовательно можно предположить, что переменная **max21days** включает в себя значения переменной **max14days** и так далее.*

*Аналогичные опасения возникают относительно переменных **Active_to_All_prc** (Отношение активных счетов ко всем счетам) и **numAccountClosed** (Кол-во закрытых счетов), между которыми наблюдается отрицательная корреляция: **corr** = – 0,48. Иными словами, при росте одной из них на 1, другая уменьшится на 0,48. Однако это также логично, поскольку можно предположить, что количество закрытых аккаунтов напрямую и отрицательно влияет на общее число активных счетов.*

Часть 1: Исследование данных. Подготовка данных для сегментации

Рассчитаем кол-во уникальных, нулевых и пропущенных значений, а также их долю в % от общего кол-ва

Общее количество строк: 10242.

Это можно, посчитав количество значений переменной ID, так как у нее нет пропущенных значений и 100% уникальность.

Также можно заметить, что:

- Весьма низкие показатели по доле уникальных значений (почти все 0), что неудивительно для категориальных переменных, но необычно для числовых
- В то время как показатели доли нулевых и пропущенных гораздо выше:

	Column	Unique	%unique	Zero	%zero	Null	%null
0	ID	10242	100.00	0	0.00	0	0.00
1	INCOME_BASE_TYPE	4	0.04	0	0.00	73	0.71
2	CREDIT_PURPOSE	10	0.10	0	0.00	0	0.00
3	INSURANCE_FLAG	2	0.02	4037	39.42	1	0.01
4	DTI	60	0.59	0	0.00	106	1.03
5	SEX	2	0.02	0	0.00	0	0.00
6	FULL_AGE_CHILD_NUMBER	6	0.06	6072	59.29	2	0.02
7	DEPENDANT_NUMBER	4	0.04	10206	99.65	0	0.00
8	EDUCATION	9	0.09	0	0.00	1	0.01
9	EMPL_TYPE	9	0.09	0	0.00	10	0.10
10	EMPL_SIZE	8	0.08	0	0.00	105	1.03
11	BANKACCOUNT_FLAG	4	0.04	6224	60.77	2333	22.78
12	Period_at_work	363	3.54	0	0.00	2333	22.78
13	age	40	0.39	0	0.00	2333	22.78
14	EMPL_PROPERTY	12	0.12	0	0.00	2333	22.78
15	EMPL_FORM	6	0.06	0	0.00	6241	60.94
16	FAMILY_STATUS	6	0.06	0	0.00	6241	60.94
17	max90days	19	0.19	1053	10.28	6278	61.30
18	max60days	17	0.17	1562	15.25	6278	61.30
19	max30days	15	0.15	2008	19.61	6278	61.30
20	max21days	14	0.14	2391	23.35	6278	61.30
21	max14days	14	0.14	2608	25.46	6278	61.30

22	avg_num_delay	1167	11.39	1626	15.88	6513	63.59
23	if_zalog	2	0.02	2540	24.80	6503	63.49
24	num_AccountActive180	7	0.07	2623	25.61	6503	63.49
25	num_AccountActive90	5	0.05	3193	31.18	6503	63.49
26	num_AccountActive60	4	0.04	3411	33.30	6503	63.49
27	Active_to_All_prc	97	0.95	500	4.88	6503	63.49
28	numAccountActiveAll	13	0.13	480	4.69	6503	63.49
29	numAccountClosed	25	0.24	439	4.29	6503	63.49
30	sum_of_paym_months	327	3.19	10	0.10	6503	63.49
31	all_credits	30	0.29	0	0.00	6503	63.49
32	Active_not_cc	8	0.08	1273	12.43	6503	63.49
33	own_closed	9	0.09	2160	21.09	6503	63.49
34	min_MnthAfterLoan	96	0.94	147	1.44	6503	63.49
35	max_MnthAfterLoan	133	1.30	10	0.10	6503	63.49
36	dlq_exist	2	0.02	1636	15.97	6503	63.49
37	thirty_in_a_year	2	0.02	3196	31.20	6503	63.49
38	sixty_in_a_year	2	0.02	3427	33.46	6503	63.49
39	ninety_in_a_year	2	0.02	3513	34.30	6503	63.49
40	thirty_vintage	2	0.02	3629	35.43	6503	63.49
41	sixty_vintage	2	0.02	3690	36.03	6503	63.49
42	ninety_vintage	2	0.02	3681	35.94	6503	63.49

- Доля пропущенных значений у большей части переменных превышает 61%
- Доля нулевых значений :
 - У большей части переменных варьируется в промежутке от 10 до 36 % (10-40%)
 - Максимальна и практически равна 100% у переменной **DEPENDANT_NUMBER** (Кол-во иждивенцев)

Часть 1: Исследование данных. Подготовка данных для сегментации

Далее необходимо почистить наши данные, чтобы подготовить их для сегментации. Прежде всего взглянем на каждую переменную по отдельности, чтобы понять, стоит ли ее видоизменять и каким образом.

(Например, удалять или восстанавливать значения)

Начнем с категориальных переменных:


Сразу заметим, что переменные «Номер варианта» и «ID» можно удалить, поскольку номер варианта вообще не имеет отношения к данным, а Идентификатор клиента обладает 100% уникальностью (то есть для каждого клиента персональный), а значит не коррелирует ни с одной из переменных, а лишь служит для опознавания клиента.

- **INCOME_BASE_TYPE** (Подтверждение дохода) может принимать 5 различных значений, включая значение N/A в случае пропуска.
- **EDUCATION** (Образование) может принимать 10 различных значений уровня образования, включая значение N/A (1 шт), а также значения «*п.а.*» (30 шт)
- **EMPL_TYPE** (Должность) – 10 различных значений, включая значение N/A в случае пропуска.

Column	Unique ↓
⊕ ID	100.00% (10,242)

▼ Category
📄 BANKACCOUNT_FLAG - 5
📄 CREDIT_PURPOSE - 10
📄 dlq_exist - 3
📄 EDUCATION - 10
📄 EMPL_FORM - 7
📄 EMPL_PROPERTY - 13
📄 EMPL_SIZE - 9
📄 EMPL_TYPE - 10
📄 FAMILY_STATUS - 7
📄 ID - 10K
📄 if_zalog - 3
📄 INCOME_BASE_TYPE - 5
📄 INSURANCE_FLAG - 3
📄 ninety_in_a_year - 3
📄 ninety_vintage - 3
📄 SEX - 2
📄 sixty_in_a_year - 3
📄 sixty_vintage - 3
📄 thirty_in_a_year - 3
📄 thirty_vintage - 3

- **EMPL_SIZE** (Зарплата) – 9 различных значений, включая пропуски и «*n.a.*» значений (в совокупности их 110 шт.). Данная переменная также может принимать представленные справа значения. Заметим, что переменная может принимать 2 практически дублирующих друг друга значения: «>100» и «>= 100». В дальнейшем для удобства работы с данными, а также удобства интерпретации данных объединим эти переменные.



☒	*n.a.*
☒	< 50
☒	>=100
☒	>=150
☒	>=200
☒	>=50
☒	>100
☒	>250
☒	(Blanks)

- **BANKACCOUNT_FLAG** (Кол-во аккаунтов у клиента) может принимать 5 различных значений (от 0 до 4 + пропуски). Однако нам также дано, что порядковый номер данной переменной назначается следующим образом:

- 0 – нет онлайн -кабинета
- 1 – есть один онлайн-кабинет
- 2 и более – заходил в онлайн кабинет с другого устройства

Следовательно, для удобства работы с данными и их интерпретации далее присвоим 3 и 4 значение 2, поскольку все они означают одно и то же.

- **CREDIT_PURPOSE** (Цель получения кредита) может принимать 10 различных значений, при чем пропуски отсутствуют.
- **SEX** (Пол) может принимать 2 значений (мужской/женский), пропуски отсутствуют

Column	Null ↑	Unique
ID		100.00% (10,242)
CREDIT_PURPOSE		0.10% (10)
DEPENDANT_NUMBER		0.04% (4)
SEX		0.02% (2)

Таблица, иллюстрирующая переменные, в которых пропуски отсутствуют

- **EMPL_PROPERTY** (Сфера бизнеса работодателя) – 12 различных сфер + пропуски (2333 шт)

- **EMPL_FORM** (Организационно - правовая форма) – 7 различных значений (мода – ООО) , включая пропуски (6241 шт)

- **FAMILY_STATUS** (Семейный статус) – 7 различных значений (мода – женат/замужем) , включая пропуски (6241 шт)

Заметим, что не только количество пропусков, но и сами пропуски у переменных **EMPL_FORM** и **FAMILY_STATUS** совпадают. Более того, при наложении определенных фильтров в Excel заметно, что **в оставшихся строках, где НЕ пропущены значения этих двух переменных, возникает 262 пропущенных значений у 8 из приведенных ниже 9 БИНАРНЫХ ПЕРЕМЕННЫХ.**

Суммарное число пропусков у этих 8 бинарных переменных равно $6503 = 6241 + 262$. То есть в 6241 случае значения пропущены в **ТЕХ ЖЕ строках**, что и у **EMPL_FORM** и **FAMILY_STATUS**

9 следующих категориальных переменных принимают бинарные значения 1/0 в случаях да/нет соответственно.

Общее число значений: 3, так как возможен пропуск / NaN / (Blank):

- **INSURANCE_FLAG** Страхование заемщика при получении кредита – всего 1 пропуск
- **if_zalog** (Наличие залога (квартира,машина)) – **6503 шт пропусков**
- **dlq_exist** (Наличие просрочки на данный момент) – **6503 шт пропусков**
- **thirty_in_a_year** (Просрочка больше 30 дней за последний год) – **6503 шт пропусков**
- **sixty_in_a_year** (Просрочка больше 60 дней за последний год) – **6503 шт пропусков**
- **ninety_in_a_year** (Просрочка больше 90 дней за последний год) – **6503 шт пропусков**
- **thirty_vintage** (Просрочка больше 30 дней, когда-либо) – **6503 шт пропусков**
- **sixty_vintage** (Просрочка больше 60 дней, когда-либо) – **6503 шт пропусков**
- **ninety_vintage** (Просрочка больше 90 дней, когда-либо) – **6503 шт пропусков**

Вследствие сказанного выше о совпадении пропусков, можно смело удалять данные строки, поскольку в них пропущена значительная часть переменных. Более того, данное решение кажется более корректным, поскольку это категориальные переменные, а значит восстановление значений может привести к ошибке.

Далее посмотрим на количественные переменные:

Если в случае с категориальными переменными мы не можем посчитать среднее, и эффективнее удалить строки, то в случае с **количественными переменными** мы можем таким образом **восстановить пропущенные значения**.

Заметим, что практически по всем количественным переменным мы видим **значительное количество пропущенных значений (более 61%)**.

Чтобы обработать пропущенные значения можно воспользоваться методом **Импутации «среднего»** или **«наиболее ожидаемого» значения**. Однако мы рискуем испортить выборочное распределение внутри будущих сегментов, поэтому будем восстанавливать значения уже после удаления строк с пропусками у категориальных переменных и только там, где пропущено менее половины значений.

Рассчитаем среднее значение, медиану, стандартное отклонение, минимальное и максимальное значение, а также взглянем на каждую переменную по отдельности.

Column	Null ↓	Unique
⊕ avg_num_delay	63.59% (6,513)	31.30% (1,1...
⊕ sum_of_paym_months	63.49% (6,503)	8.75% (327)
⊕ max_MnthAfterLoan	63.49% (6,503)	3.56% (133)
⊕ Active_to_All_prc	63.49% (6,503)	2.59% (97)
⊕ min_MnthAfterLoan	63.49% (6,503)	2.57% (96)
⊕ all_credits	63.49% (6,503)	0.80% (30)
⊕ numAccountClosed	63.49% (6,503)	0.67% (25)
⊕ numAccountActiveAll	63.49% (6,503)	0.35% (13)
⊕ own_closed	63.49% (6,503)	0.24% (9)
⊕ Active_not_cc	63.49% (6,503)	0.21% (8)
⊕ num_AccountActive180	63.49% (6,503)	0.19% (7)
⊕ num_AccountActive90	63.49% (6,503)	0.13% (5)
⊕ num_AccountActive60	63.49% (6,503)	0.11% (4)

Column	Null ↓	Unique
⊕ max90days	61.30% (6,278)	0.48% (19)
⊕ max60days	61.30% (6,278)	0.43% (17)
⊕ max30days	61.30% (6,278)	0.38% (15)
⊕ max14days	61.30% (6,278)	0.35% (14)
⊕ max21days	61.30% (6,278)	0.35% (14)

Column	Null ↓	Unique
⊕ Period_at_work	22.78% (2,333)	4.59% (363)
⊕ age	22.78% (2,333)	0.51% (40)
⊕ DTI	1.03% (106)	0.59% (60)
⊕ FULL_AGE_CHILD_NUMBER	0.02% (2)	0.06% (6)
⊕ DEPENDANT_NUMBER		0.04% (4)

	count	mean	median	std	min	max	%_zero	%_null
DTI	10136.0	0.0	0.0	0.0	0.0	1.0	0.0	1.03
FULL_AGE_CHILD_NUMBER	10240.0	1.0	0.0	1.0	0.0	5.0	59.3	0.02
DEPENDANT_NUMBER	10242.0	0.0	0.0	0.0	0.0	3.0	99.7	0.00
Period_at_work	7909.0	66.0	44.0	66.0	5.0	481.0	0.0	22.78
age	7909.0	36.0	35.0	9.0	23.0	62.0	0.0	22.78
max90days	3964.0	2.0	1.0	2.0	0.0	23.0	10.3	61.30
max60days	3964.0	1.0	1.0	2.0	0.0	22.0	15.3	61.30
max30days	3964.0	1.0	0.0	1.0	0.0	21.0	19.6	61.30
max21days	3964.0	1.0	0.0	1.0	0.0	16.0	23.4	61.30
max14days	3964.0	1.0	0.0	1.0	0.0	16.0	25.5	61.30
avg_num_delay	3729.0	0.0	0.0	0.0	0.0	1.0	15.9	63.59
num_AccountActive180	3739.0	0.0	0.0	1.0	0.0	6.0	25.6	63.49
num_AccountActive90	3739.0	0.0	0.0	0.0	0.0	4.0	31.2	63.49
num_AccountActive60	3739.0	0.0	0.0	0.0	0.0	3.0	33.3	63.49
Active_to_All_prc	3739.0	0.0	0.0	0.0	0.0	1.0	4.9	63.49
numAccountActiveAll	3739.0	2.0	2.0	2.0	0.0	12.0	4.7	63.49
numAccountClosed	3739.0	4.0	3.0	3.0	0.0	31.0	4.3	63.49
sum_of_paym_months	3739.0	81.0	62.0	71.0	0.0	793.0	0.1	63.49
all_credits	3739.0	6.0	5.0	4.0	1.0	37.0	0.0	63.49
Active_not_cc	3739.0	1.0	1.0	1.0	0.0	8.0	12.4	63.49
own_closed	3739.0	1.0	0.0	1.0	0.0	8.0	21.1	63.49
min_MnthAfterLoan	3739.0	14.0	9.0	15.0	-1.0	110.0	1.4	63.49
max_MnthAfterLoan	3739.0	61.0	66.0	31.0	0.0	416.0	0.1	63.49

При помощи икслея, а также запроса типа данных на Python мы выяснили, что все количественные переменные принимают либо числовые значения (float), или же пропущены (NaN или Blank).

Следовательно, мы не будем корректировать данные, а только заполним пропуски. Заметим, что % пропусков у некоторых количественных переменных совпадает с категориальными. В действительности, сами пропуски также совпадают.

Обратим внимание, что несмотря на большое количество нулевых значений у переменной **DEPENDANT_NUMBER** (Кол-во иждивенцев), мы не можем их удалить, поскольку они несут смысловую нагрузку – отсутствие иждивенцев в семье. Аналогично важны нули в переменной **FULL_AGE_CHILD_NUMBER** (Кол-во лет ребенку), так как они обозначают, что в этих семьях (в 59.3% семей) ноль детей.

Обозначения и комментарии по остальным числовым переменным:

- | | |
|---|--|
| - DTI (debt-to-income ratio — отношение долга к доходам) | - sum_of_paym_months (Сумма платежей за последний месяц (тыс.)) |
| - FULL_AGE_CHILD_NUMBER (Кол-во лет ребенку) – будем рассматривать как целочисленную числовую переменную (integer) | - all_credits (Кол-во кредитов) – ВАЖНАЯ ПЕРЕМЕННАЯ |
| - DEPENDANT_NUMBER (Кол-во иждивенцев) – принимает 4 значения (от 0 до 3) | - Active_not_cc (Активные кредитные счета, но не кредитная карта) |
| - Period_at_work (Время работы (кол-во дней)) | - own_closed (Кол-во закрытых кредитов) |
| - age (Возраст) – будем рассматривать как целочисленную числовую переменную (integer) | - min_MnthAfterLoan (Минимальное кол-во месяцев, которое прошло с момента взятия прошлого кредита, то есть как давно выдали последний кредит клиенту) |
| - avg_num_delay (Среднее кол-во задержки оплаты) | - max_MnthAfterLoan (Кол-во месяцев прошедшее с момента выдачи первого кредита) |

Связанные переменные (Сильная и умеренная положительная корреляционная связь, значения одной переменной могут включать значения другой. Например, кол-во активных счетов за последние 90 дней может включать в себя кол-во запросов за последние 60 дней)

- **num_AccountActive180** (Кол-во активных счетов за последние 180 дней)

- **num_AccountActive90** (Кол-во активных счетов за последние 90 дней)

- **num_AccountActive60** (Кол-во активных счетов за последние 60 дней)

*Связанные переменные (Умеренная положительная корреляционная связь между переменными **Active_to_All_prc** и **numAccountActiveAll**, умеренная отрицательная корреляционная связь между переменными **Active_to_All_prc** и **numAccountClosed** – предположительно могут возникать из-за прямой функциональной зависимости переменных)*

- **Active_to_All_prc** (Отношение активных счетов ко всем счетам)

- **numAccountActiveAll** (Кол-во открытых счетов)

- **numAccountClosed** (Кол-во закрытых счетов)

Связанные переменные (Сильная и умеренная положительная корреляционная связь, значения одной переменной могут включать значения другой. Например, кол-во запросов за последние 60 дней может включать в себя кол-во запросов за последние 30, 21 и 14 дней):




- **max90days** (Кол-во запросов в бюро кредитных историй за последние 90 дней)

- **max60days** (Кол-во запросов в бюро кредитных историй за последние 60 дней)

- **max30days** (Кол-во запросов в бюро кредитных историй за последние 30 дней)

- **max21days** (Кол-во запросов в бюро кредитных историй за последние 21 дней)

- **max14days** (Кол-во запросов в бюро кредитных историй за последние 14 дней)



Действия:

- 1) Удаляем Номер варианта и **ID** (100% уникальность говорит о независимости данной переменной от других – оставим ID только в финальной витрине данных, чтобы идентифицировать клиентов, но удалим как переменную при проведении дальнейшего анализа и сегментации)
- 2) У переменной **EDUCATION** (Образование) вручную заменяем «*п.а.*» на пропуски (то есть удаляем в Excel и оставляем пропуски)
- 3) У переменной **EMPL_SIZE** (Зарплата) вручную заменяем «*п.а.*» на пропуски (то есть удаляем в Excel и оставляем пропуски)
- 4) У переменной **EMPL_SIZE** (Зарплата) заменяем «>100» на «>= 100»
- 5) У переменной **BANKACCOUNT_FLAG** (Кол-во аккаунтов у клиента) значения 3 и 4 заменяем на 2
- 6) Удаляем 6241 пропущенную строку у переменных **EMPL_FORM** (Организационно - правовая форма) и **FAMILY_STATUS** (Семейный статус)
- 7) Из оставшихся 4001 строки удаляем еще 262 строки, пропущенные у 8ми бинарных переменных, упомянутых ранее (например, **if_zalog** (Наличие залога (квартира, машина)))
- 8) Проанализируем количественные переменные и оставшиеся пропуски в категориальном в полученном датафрейме из 3739 строк:

Заметим, что число пропусков сократилось у ВСЕХ переменных, а не только у категориальных.

В новом датафрейме практически нет пропущенных значений, то есть **более высокая полнота данных по оставшимся 3739 клиентам.**

Ту малую часть пропусков, которые остались у количественных переменных, можно без смысловых потерь и глобальных логических ошибок заменить методом **Импутации «среднего»** или **«наиболее ожидаемого» значения.**

Часть 1: Исследование данных. Подготовка данных для сегментации

NEW

	Column	Unique	%unique	Zero	%zero	Null	%null
0	INCOME_BASE_TYPE	4	0.11	0	0.00	0	0.00
1	CREDIT_PURPOSE	10	0.27	0	0.00	0	0.00
2	INSURANCE_FLAG	2	0.05	1448	38.73	0	0.00
3	DTI	58	1.55	0	0.00	0	0.00
4	SEX	2	0.05	0	0.00	0	0.00
5	FULL_AGE_CHILD_NUMBER	5	0.13	2238	59.86	1	0.03
6	DEPENDANT_NUMBER	4	0.11	3722	99.55	0	0.00
7	EDUCATION	8	0.21	0	0.00	14	0.37
8	EMPL_TYPE	9	0.24	0	0.00	0	0.00
9	EMPL_SIZE	2	0.05	0	0.00	4	0.11
10	BANKACCOUNT_FLAG	3	0.08	3073	82.19	0	0.00
11	Period_at_work	269	7.19	0	0.00	0	0.00
12	age	39	1.04	0	0.00	0	0.00
13	EMPL_PROPERTY	5	0.13	0	0.00	0	0.00
14	EMPL_FORM	6	0.16	0	0.00	0	0.00
15	FAMILY_STATUS	6	0.16	0	0.00	0	0.00
16	max90days	18	0.48	1047	28.00	1	0.03
17	max60days	16	0.43	1556	41.62	1	0.03
18	max30days	14	0.37	2002	53.54	1	0.03
19	max21days	13	0.35	2384	63.76	1	0.03
20	max14days	12	0.32	2598	69.48	1	0.03
21	avg_num_delay	1167	31.21	1626	43.49	10	0.27

VS

OLD

	Column	Unique	%unique	Zero	%zero	Null	%null
0	ID	10242	100.00	0	0.00	0	0.00
1	INCOME_BASE_TYPE	4	0.04	0	0.00	73	0.71
2	CREDIT_PURPOSE	10	0.10	0	0.00	0	0.00
3	INSURANCE_FLAG	2	0.02	4037	39.42	1	0.01
4	DTI	60	0.59	0	0.00	106	1.03
5	SEX	2	0.02	0	0.00	0	0.00
6	FULL_AGE_CHILD_NUMBER	6	0.06	6072	59.29	2	0.02
7	DEPENDANT_NUMBER	4	0.04	10206	99.65	0	0.00
8	EDUCATION	9	0.09	0	0.00	1	0.01
9	EMPL_TYPE	9	0.09	0	0.00	10	0.10
10	EMPL_SIZE	8	0.08	0	0.00	105	1.03
11	BANKACCOUNT_FLAG	4	0.04	6224	60.77	2333	22.78
12	Period_at_work	363	3.54	0	0.00	2333	22.78
13	age	40	0.39	0	0.00	2333	22.78
14	EMPL_PROPERTY	12	0.12	0	0.00	2333	22.78
15	EMPL_FORM	6	0.06	0	0.00	6241	60.94
16	FAMILY_STATUS	6	0.06	0	0.00	6241	60.94
17	max90days	19	0.19	1053	10.28	6278	61.30
18	max60days	17	0.17	1562	15.25	6278	61.30
19	max30days	15	0.15	2008	19.61	6278	61.30
20	max21days	14	0.14	2391	23.35	6278	61.30
21	max14days	14	0.14	2608	25.46	6278	61.30

Часть 1: Исследование данных. Подготовка данных для сегментации

NEW

22	if_zalog	2	0.05	2540	67.93	0	0.00
23	num_AccountActive180	7	0.19	2623	70.15	0	0.00
24	num_AccountActive90	5	0.13	3193	85.40	0	0.00
25	num_AccountActive60	4	0.11	3411	91.23	0	0.00
26	Active_to_All_prc	97	2.59	500	13.37	0	0.00
27	numAccountActiveAll	13	0.35	480	12.84	0	0.00
28	numAccountClosed	25	0.67	439	11.74	0	0.00
29	sum_of_paym_months	327	8.75	10	0.27	0	0.00
30	all_credits	30	0.80	0	0.00	0	0.00
31	Active_not_cc	8	0.21	1273	34.05	0	0.00
32	own_closed	9	0.24	2160	57.77	0	0.00
33	min_MnthAfterLoan	96	2.57	147	3.93	0	0.00
34	max_MnthAfterLoan	133	3.56	10	0.27	0	0.00
35	dlq_exist	2	0.05	1636	43.76	0	0.00
36	thirty_in_a_year	2	0.05	3196	85.48	0	0.00
37	sixty_in_a_year	2	0.05	3427	91.66	0	0.00
38	ninety_in_a_year	2	0.05	3513	93.96	0	0.00
39	thirty_vintage	2	0.05	3629	97.06	0	0.00
40	sixty_vintage	2	0.05	3690	98.69	0	0.00
41	ninety_vintage	2	0.05	3681	98.45	0	0.00

VS

OLD



22	avg_num_delay	1167	11.39	1626	15.88	6513	63.59
23	if_zalog	2	0.02	2540	24.80	6503	63.49
24	num_AccountActive180	7	0.07	2623	25.61	6503	63.49
25	num_AccountActive90	5	0.05	3193	31.18	6503	63.49
26	num_AccountActive60	4	0.04	3411	33.30	6503	63.49
27	Active_to_All_prc	97	0.95	500	4.88	6503	63.49
28	numAccountActiveAll	13	0.13	480	4.69	6503	63.49
29	numAccountClosed	25	0.24	439	4.29	6503	63.49
30	sum_of_paym_months	327	3.19	10	0.10	6503	63.49
31	all_credits	30	0.29	0	0.00	6503	63.49
32	Active_not_cc	8	0.08	1273	12.43	6503	63.49
33	own_closed	9	0.09	2160	21.09	6503	63.49
34	min_MnthAfterLoan	96	0.94	147	1.44	6503	63.49
35	max_MnthAfterLoan	133	1.30	10	0.10	6503	63.49
36	dlq_exist	2	0.02	1636	15.97	6503	63.49
37	thirty_in_a_year	2	0.02	3196	31.20	6503	63.49
38	sixty_in_a_year	2	0.02	3427	33.46	6503	63.49
39	ninety_in_a_year	2	0.02	3513	34.30	6503	63.49
40	thirty_vintage	2	0.02	3629	35.43	6503	63.49
41	sixty_vintage	2	0.02	3690	36.03	6503	63.49
42	ninety_vintage	2	0.02	3681	35.94	6503	63.49

Удаление/восстановление значений в оставшихся пропусках


- Категориальные переменные – пропусков не так много, было решено их удалить:

У переменной **EMPL_SIZE** все еще есть 4 пропущенных значений (Missing). Удалим эти строки.

Можно заметить, что после очищения нашей выборки от строк с большим количеством пропусков, у переменной **EMPL_SIZE** остались только значения «>250» и «<50», однако это не критично, поскольку они суммарно составляют более 78% выборки.



У переменной **EDUCATION** (Образование) 14 пропусков. Удалим эти строки.



Также заметим, что вторым наиболее часто встречающимся значением переменной является смешенное значение «Высшее/Второе высшее/Ученая степень», которая объединяет в себе 3 других. Мы не можем удалить эти значения, поскольку их слишком много. Также мы не можем объединить ее с другими, поскольку это может быть некорректно. Данную проблему попробуем разрешить при кодировании переменных перед сегментацией.

Оставшееся количество строк: 3724

- **Количественные переменные – заменяем средним значением**

Переменная **FULL_AGE_CHILD_NUMBER** (Кол-во лет ребенку) – 1 пропуск, можем заменить средним значением: 1.0

В каждой из переменных: **max90days**, **ma60days**, **max30days**, **max21days**, **max14days** (Кол-во запросов в бюро кредитных историй за последние 90, 60, 30, 21 и 14 дней) – 1 пропуск.

Заметим, что пропуски этих переменных все находятся в одной и той же строке. Это легко объясняется тем, что (как уже было отмечено ранее) между данными переменными в датафрейме может наблюдаться прямая зависимость.

В переменной **avg_num_delay** (Среднее кол-во задержки оплаты) – 10 пропусков.


Эти пропуски мы также заменим **средними значениями** этих переменных, рассчитанных **по новому датафрейму**:

5	FULL_AGE_CHILD_NUMBER	5	0.13	2238	59.86	1	0.03
6	DEPENDANT_NUMBER	4	0.11	3722	99.55	0	0.00
7	EDUCATION	8	0.21	0	0.00	14	0.37
8	EMPL_TYPE	9	0.24	0	0.00	0	0.00
9	EMPL_SIZE	2	0.05	0	0.00	4	0.11
10	BANKACCOUNT_FLAG	3	0.08	3073	82.19	0	0.00
11	Period_at_work	269	7.19	0	0.00	0	0.00
12	age	39	1.04	0	0.00	0	0.00
13	EMPL_PROPERTY	5	0.13	0	0.00	0	0.00
14	EMPL_FORM	6	0.16	0	0.00	0	0.00
15	FAMILY_STATUS	6	0.16	0	0.00	0	0.00
16	max90days	18	0.48	1047	28.00	1	0.03
17	max60days	16	0.43	1556	41.62	1	0.03
18	max30days	14	0.37	2002	53.54	1	0.03
19	max21days	13	0.35	2384	63.76	1	0.03
20	max14days	12	0.32	2598	69.48	1	0.03
21	avg_num_delay	1167	31.21	1626	43.49	10	0.27

	mean
FULL_AGE_CHILD_NUMBER	1.0
max90days	2.0
max60days	1.0
max30days	1.0
max21days	1.0
max14days	0.0
avg_num_delay	0.060739










Новая корреляционная матрица

После удаления всех пропусков
немного изменилась корреляция
между переменными, но не более
чем на 0,03




Исследуем распределение данных по полу и другим категориальным показателям (всего 19 штук):

(Посмотрим на частоту возникновения различных категориальных признаков)



Frequency of CREDIT_PURPOSE


CREDIT_PURPOSE



CREDIT_PURPOSE	Frequency
Ремонт	2,086
Покупка автомобиля	634
Покупка недвижимости/ строительство	456
Отпуск	169
Другое	124
Покупка мебели	76
Обучение	49
Покупка бытовой техники	47
Лечение	45
Покупка земли	38

Frequency of EMPL_FORM


EMPL_FORM



EMPL_FORM	Frequency
ООО	2,542
ЗАО	505
ОАО	363
Государственное предприятие	114
Иная форма	102
Индивидуальный предприниматель	98

Frequency of EMPL_TYPE


EMPL_TYPE









EMPL_TYPE	Frequency
специалист	1,373
менеджер среднего звена	865
вспомогательный персонал	655
рабочий	336
менеджер высшего звена	314
торговый представитель	90
менеджер по продажам	88
страховой агент	2
другое	1

Frequency of FAMILY_STATUS

FAMILY_STATUS




FAMILY_STATUS	Frequency
женат / замужем	2,036
холост / не замужем	1,204
разведен / разведена	214
гражданский брак	161
повторный брак	106
вдовец / вдова	3



Данные графики иллюстрируют **частоту возникновения признаков** категориальных переменных в очищенном датафрейме.

Судя по графикам, а также рассчитанным модальным значениям – наиболее часто встречающимся в нашей выборке (по категориальным признакам) клиентом является:

- Женатый мужчина
- Без детей или иждивенцев в семье
- Имеющий высшее образование
- Работающий на должности «специалист»
- Получающий зп в размере «>250» на счет
- Сфера бизнеса работодателя: Торговля
- Организационно - правовая форма: ООО
- Берущий кредит на ремонт
- Страхующий этот кредит
- Не имеющий залога



```
Out[64]: DTI 0.0
FULL_AGE_CHILD_NUMBER 1.0
DEPENDANT_NUMBER 0.0
Period at work 57.0
age 36.0
max90days 2.0
max60days 1.0
max30days 1.0
max21days 1.0
max14days 0.0
avg_num_delay 0.0
num_AccountActive180 0.0
num_AccountActive90 0.0
num_AccountActive60 0.0
Active_to_All_prc 0.0
numAccountActiveAll 2.0
numAccountClosed 4.0
sum_of_paym_months 81.0
all_credits 6.0
Active_not_cc 1.0
own_closed 1.0
min_MnthAfterLoan 14.0
max_MnthAfterLoan 61.0
dtype: float64
```

INCOME_BASE_TYPE	Поступление зарплаты на счет
CREDIT_PURPOSE	Ремонт
INSURANCE_FLAG	1
DTI	1.0
SEX	мужской
FULL_AGE_CHILD_NUMBER	0.0
DEPENDANT_NUMBER	0.0
EDUCATION	высшее
EMPL_TYPE	специалист
EMPL_SIZE	>250
BANKACCOUNT_FLAG	0
Period at work	6.0
age	28
EMPL_PROPERTY	Торговля
EMPL_FORM	ООО
FAMILY_STATUS	женат / замужем
max90days	1.0
max60days	0.0
max30days	0.0
max21days	0.0
max14days	0.0
avg_num_delay	0.0
if_zalog	0
num_AccountActive180	0.0
num_AccountActive90	0.0
num_AccountActive60	0.0
Active_to_All_prc	0.0
numAccountActiveAll	1.0
numAccountClosed	1.0
sum_of_paym_months	25.0
all_credits	2.0
Active_not_cc	1.0
own_closed	0.0
min_MnthAfterLoan	2.0
max_MnthAfterLoan	80.0
dlq_exist	1
thirty_in_a_year	0
sixty_in_a_year	0
ninety_in_a_year	0
thirty_vintage	0
sixty_vintage	0
ninety_vintage	0

Можно заметить, что наиболее часто в выборке встречается значение переменной возраста, равное 28 лет. Однако было принято решение воспринимать **age** (возраст) как количественную переменную. В качестве характеристики «типичного клиента» будет корректнее взять средний возраст по новой выборке: **36 лет**

ИТОГОВАЯ ВИТРИНА ДАННЫХ

ДЛЯ СЕГМЕНТАЦИИ

- Без пропусков
- Без некорректных значений
- **Максимальная полнота данных по каждому клиенту**

Для проведения анализа данных, мы выкинули ID как переменную исключительно идентифицирующую и не имеющую влияния на другие. Однако ее необходимо включить в итоговую витрину данных – внутреннюю базу данных компании по клиентам, из которой при необходимости мы сможем достать **информацию по конкретному клиенту**.

(При проведении сегментации переменная ID не будет использоваться, однако ее необходимо сохранить в итоговой витрине данных)

	ID	INCOME_BASE_TYPE	CREDIT_PURPOSE	INSURANCE_FLAG	DTI	SEX	FULL_AGE_CHILD_NUMBER	DEPENDANT_NUMBER	EDUCATION
0	1000059	Форма банка (без печати работодателя)	Ремонт	1	0.49	женский	0	0	Высшее/ Второе высшее/ Ученая степень
1	1000079	Поступление зарплаты на счет	Ремонт	1	0.54	женский	0	0	высшее
2	1000139	Форма банка (без печати работодателя)	Лечение	0	0.29	мужской	0	0	среднее- специальное
3	1000179	Поступление зарплаты на счет	Ремонт	0	0.39	мужской	2	0	второе высшее
4	1000199	Поступление зарплаты на счет	Покупка автомобиля	1	0.49	мужской	1	0	Высшее/ Второе высшее/ Ученая степень
...	...	...	...	...	...	...	...	...	...
3719	1204599	2НДФЛ	Покупка автомобиля	0	0.46	мужской	0	0	второе высшее
3720	1204639	Форма банка (без печати работодателя)	Покупка недвижимости/ строительство	0	0.38	мужской	0	0	Высшее/ Второе высшее/ Ученая степень
3721	1204719	Поступление зарплаты на счет	Ремонт	1	0.49	женский	0	0	высшее
3722	1204779	Поступление зарплаты на счет	Ремонт	0	0.14	мужской	0	0	Высшее/ Второе высшее/ Ученая степень
3723	1204839	2НДФЛ	Ремонт	0	0.43	женский	0	0	высшее
3724 rows × 43 columns									

EMPL_TYPE	EMPL_SIZE	...	own_closed	min_MnthAfterLoan	max_MnthAfterLoan	dlq_exist	thirty_in_a_year	sixty_in_a_year	ninety_in_a_year	thirty_vintage	sixty_vintage	ninety_vintage
вспомогательный персонал	>250	...	0	26	52	1	0	0	0	0	0	0
специалист	>250	...	0	18	76	1	0	0	0	0	0	0
специалист	< 50	...	0	4	98	1	0	0	0	0	0	0
менеджер среднего звена	>250	...	1	1	49	0	0	0	0	0	0	0
специалист	>250	...	0	1	99	1	0	0	0	0	0	0
...	...	...	...	...	...	...	...	...	...	...	...	...
вспомогательный персонал	>250	...	0	12	44	0	0	0	0	0	0	0
менеджер среднего звена	>250	...	0	5	92	1	0	0	0	0	0	0
специалист	>250	...	0	6	93	1	1	1	1	0	0	1
специалист	>250	...	0	3	34	1	0	0	0	1	0	0
специалист	>250	...	1	6	94	1	1	1	1	1	1	1

Итоговая витрина данных для проведения сегментации состоит из 23 количественных переменных и 19 категориальных (без ID). Однако среди категориальных есть как бинарные (уже закодированные переменные), как и те, которые еще предстоит перевести к целочисленным для дальнейшего деления на кластеры.

Для проведения кластеризации через Python необходимо перевести 10 категориальных показателей в целочисленные.

Кодируем вручную к EXCEL:

- SEX – 2 значения, бинарная переменная: 0 – мужчина, 1 – женщина.
- EDUCATION – 8 значений: кодируем следующим образом:
 - 1 = Неполное среднее
 - 2 = среднее-специальное
 - 3 = среднее
 - 4 = незаконченное высшее
 - 5 = второе высшее
 - 6 = высшее
 - 7 = ученая степень
 - Высшее/Второе высшее/Ученая степень закодируем цифрой 6 – средним среди 5, 6 и 7, то есть высшим, вторым высшим и ученой степенью. Это может быть не совсем корректно, поэтому при сегментации, переменную образования мы будем брать в расчет в последнюю очередь.

One-hot encoding:

INCOME_BASE_TYPE – 4 значения

CREDIT_PURPOSE – 10 значений

EMPL_TYPE – 9 значений

EMPL_SIZE – 2 значения

EMPL_PROPERTY – 5 значений

EMPL_FORM – 6 значений

FAMILY_STATUS – 6 значений

	0	1	2	3	4	5	6	7	8	9	...	3714	3715	3716	3717	3718	3719	3720	3721	3722	3723
Форма банка (без печати работодателя)_INCOME_BASE_TYPE	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	1.0	0.0	...	0.0	0.0	0.0	1.0	1.0	1.0	0.0	0.0	0.0	1.0
Поступление зарплаты на счет_INCOME_BASE_TYPE	0.0	1.0	0.0	1.0	1.0	1.0	1.0	0.0	0.0	0.0	...	0.0	0.0	1.0	0.0	0.0	0.0	0.0	1.0	1.0	0.0
2НДФЛ_INCOME_BASE_TYPE	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
Свободная форма с печатью работодателя_INCOME_BASE_TYPE	1.0	0.0	1.0	0.0	0.0	0.0	0.0	1.0	0.0	1.0	...	1.0	1.0	0.0	0.0	0.0	0.0	1.0	0.0	0.0	0.0
Ремонт_CREDIT_PURPOSE	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
Лечение_CREDIT_PURPOSE	0.0	0.0	1.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
Покупка автомобиля_CREDIT_PURPOSE	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
Покупка недвижимости/строительство_CREDIT_PURPOSE	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
Отпуск_CREDIT_PURPOSE	0.0	0.0	0.0	0.0	1.0	0.0	0.0	1.0	0.0	0.0	...	0.0	0.0	0.0	1.0	0.0	1.0	0.0	0.0	0.0	0.0
Покупка земли_CREDIT_PURPOSE	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
Покупка бытовой техники_CREDIT_PURPOSE	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
Покупка мебели_CREDIT_PURPOSE	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
Другое_CREDIT_PURPOSE	0.0	0.0	0.0	0.0	0.0	0.0	1.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	1.0	0.0	1.0	0.0	0.0	0.0
Обучение_CREDIT_PURPOSE	1.0	1.0	0.0	1.0	0.0	1.0	0.0	0.0	1.0	1.0	...	1.0	1.0	1.0	0.0	0.0	0.0	0.0	1.0	1.0	1.0
вспомогательный персонал_EMPL_TYPE	1.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	1.0	0.0	0.0	1.0	0.0	0.0	0.0	0.0
специалист_EMPL_TYPE	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
менеджер среднего звена_EMPL_TYPE	0.0	0.0	0.0	0.0	0.0	0.0	1.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
менеджер высшего звена_EMPL_TYPE	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
торговый представитель_EMPL_TYPE	0.0	0.0	0.0	1.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	1.0	0.0	0.0	0.0
рабочий_EMPL_TYPE	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
менеджер по продажам_EMPL_TYPE	0.0	1.0	1.0	0.0	1.0	1.0	0.0	1.0	1.0	1.0	...	1.0	1.0	0.0	1.0	1.0	0.0	0.0	1.0	1.0	1.0
страховой агент_EMPL_TYPE	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
другое_EMPL_TYPE	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
>250_EMPL_SIZE	0.0	0.0	1.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
< 50_EMPL_SIZE	1.0	1.0	0.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0	...	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0
Торговля_EMPL_PROPERTY	0.0	1.0	1.0	1.0	1.0	1.0	0.0	1.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	1.0	0.0	0.0	0.0	1.0
Другое_EMPL_PROPERTY	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	1.0	0.0	0.0	0.0	0.0	0.0
Сельское и лесное хозяйство_EMPL_PROPERTY	0.0	0.0	0.0	0.0	0.0	0.0	1.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
Информационные технологии_EMPL_PROPERTY	1.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	1.0	1.0	...	1.0	1.0	1.0	1.0	0.0	0.0	1.0	1.0	1.0	0.0
Юридические услуги_EMPL_PROPERTY	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
ООО_EMPL_FORM	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
Иная форма_EMPL_FORM	0.0	0.0	0.0	0.0	0.0	0.0	1.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	1.0	0.0	0.0	0.0	0.0	0.0
ЗАО_EMPL_FORM	0.0	0.0	0.0	0.0	1.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
ОАО_EMPL_FORM	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	1.0	0.0	0.0	0.0
Индивидуальный предприниматель_EMPL_FORM	0.0	0.0	0.0	0.0	0.0	0.0	0.0	1.0	1.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	1.0
Государственное предприятие_EMPL_FORM	1.0	1.0	1.0	1.0	0.0	1.0	0.0	0.0	0.0	1.0	...	1.0	1.0	1.0	1.0	0.0	1.0	0.0	1.0	1.0	0.0
женат / замужем_FAMILY_STATUS	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
холост / не замужем_FAMILY_STATUS	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
разведен / разведена_FAMILY_STATUS	1.0	0.0	1.0	1.0	1.0	0.0	1.0	1.0	0.0	1.0	...	0.0	1.0	0.0	1.0	0.0	0.0	0.0	0.0	1.0	1.0
гражданский брак_FAMILY_STATUS	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
повторный брак_FAMILY_STATUS	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	1.0	0.0	...	0.0	0.0	0.0	0.0	1.0	0.0	0.0	0.0	0.0	0.0
вдовец / вдова_FAMILY_STATUS	0.0	1.0	0.0	0.0	0.0	1.0	0.0	0.0	0.0	0.0	...	1.0	0.0	1.0	0.0	0.0	1.0	1.0	1.0	0.0	0.0

42 rows × 3724 columns

Закодированный датабейз будет состоять из 77 переменных

	0	1	2	3	4	5	6	7	8	9	...	3714	3715	3716	3717	3718	3719	3720	3721	3722	3723
INSURANCE_FLAG	1.00	1.00	0.00	0.00	1.00	0.0	1.00	1.00	1.00	1.00	...	1.00	0.00	1.00	1.00	0.00	0.00	0.00	1.00	0.00	0.00
DTI	0.49	0.54	0.29	0.39	0.49	0.5	0.49	0.07	0.48	0.25	...	0.49	0.23	0.29	0.31	0.41	0.46	0.38	0.49	0.14	0.43
SEX	1.00	1.00	0.00	0.00	0.00	0.0	0.00	0.00	1.00	1.00	...	1.00	1.00	1.00	1.00	1.00	0.00	0.00	1.00	0.00	1.00
FULL_AGE_CHILD_NUMBER	0.00	0.00	0.00	2.00	1.00	0.0	0.00	0.00	2.00	1.00	...	1.00	1.00	0.00	0.00	1.00	0.00	0.00	0.00	0.00	0.00
DEPENDANT_NUMBER	0.00	0.00	0.00	0.00	0.00	0.0	0.00	0.00	0.00	0.00	...	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
холост / не замужем_FAMILY_STATUS	0.00	0.00	0.00	0.00	0.00	0.0	0.00	0.00	0.00	0.00	...	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00
разведен / разведена_FAMILY_STATUS	1.00	0.00	1.00	1.00	1.00	0.0	1.00	1.00	0.00	1.00	...	0.00	1.00	0.00	1.00	0.00	0.00	0.00	0.00	1.00	1.00
гражданский брак_FAMILY_STATUS	0.00	0.00	0.00	0.00	0.00	0.0	0.00	0.00	0.00	0.00	...	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00
повторный брак_FAMILY_STATUS	0.00	0.00	0.00	0.00	0.00	0.0	0.00	0.00	1.00	0.00	...	0.00	0.00	0.00	0.00	1.00	0.00	0.00	0.00	0.00	0.00
вдовец / вдова_FAMILY_STATUS	0.00	1.00	0.00	0.00	0.00	1.0	0.00	0.00	0.00	0.00	...	1.00	0.00	1.00	0.00	0.00	1.00	1.00	1.00	0.00	0.00

77 rows × 3724 columns

Далее перед проведением сегментации:

- нормализуем наши данные и
- применим метод главных компонент – PCA (один из основных способов уменьшить размерность данных, потеряв наименьшее количество информации)

Часть 2:

Сегментация:

Кластеризация k-means и Квантили (RFM)

Часть 2: Сегментация

Провести любыми 2-мя методами сегментацию данных на выбор:

- Бизнес-правила;
- Квантили (RFM);
- Сегменты на основе данных кластеризации с учителем (Дерево решений, регрессия, нейросети, градиентный бустинг и тд);
- Без учителя (Метод К-средних, Mean-shift, DBSCAN, Иерархическая кластеризация и тд.)

Задачи, которые необходимо решить в части 2:

- ✓ Выделить сегменты клиентов согласно выбранному методу сегментации;
- ✓ Сформировать портреты клиентов на основе полученных данных - дать интерпретацию каждому полученному сегменту;
- ✓ Обосновать выбор метода - описать плюсы/минусы каждого метода на основе испытываемых данных и на основе полученного теоретического материала;

Вне зависимости от выбранного метода сегментации, выделение групп клиентов должно соответствовать следующими условиями:

- Внутри сегмента однородность максимальная;
- Между сегментами однородность минимальна


Часть 2: Сегментация

Метод 1: Сегментация без учителя. Метод k-средних

1) С помощью «метода локтя» (для k-means) определим оптимальное количество кластеров:

Построим график зависимости между значениями k и суммой квадрата внутри кластера, чтобы получить значение k . По графику видно, как снижается внутрикластерная дисперсия. Мы видим, что это снижение резко замедляется, когда значение кластеров достигает 3.

Второе замедление происходит после преодоления точки 5. Три – это довольно маленькое число кластеров (недостаточно детализации), поэтому оптимальным значением k будем считать пять.



Первым методом сегментации была выбрана кластеризация методом k-means (без учителя)

Актуальность и плюсы метода:

- Данный метод отлично подходит для сегментации рынка, в том числе и для сегментации клиентов по кредитам
- В нашей выборке присутствует весьма большое количество переменных. В связи с этим сегментация методом k-средних поможет разделить кластеры по неизвестному признаку, который будет задан самим алгоритмом метода.
- Более того, данный метод позволит корректно объединить близкие точки на карте и выявить аномалии (и соответственно отнести эти аномалии к определенным кластерам при возможности), тем самым позволив разбить данные так, чтобы клиенты в разных кластерах максимально различались, а внутри кластера были максимально схожи
- Отличная визуализация – с помощью данного метода возможно понятным образом визуализировать разбиение на кластеры

Минусы метода:

- Несмотря на то, что мы смогли определить количество кластеров с помощью метода локтя – ответ все еще остается спорным.
- Важно понимать, что такой способ кластеризации очень чувствителен к масштабированию. Результат полностью изменится, если мы будем масштабировать наши данные с помощью нормализации или стандартизации. Однако было принято решение строить кластеры на уже заранее нормализованных данных, поэтому данный минус не окажется помехой.



Примечание:

- Результаты кластеризации были подробно визуализированы в системе SAS, однако в связи с тем, что система прекратила работать, появились затруднения в том, чтобы вставить их в работу.
- Ниже прилагаются наработки в Python

Как мы видим, в обоих случаях: и трех, и пяти кластеров:

- Кластеры примерно равновелики между собой (долю значений в каждом из пяти кластеров можно посмотреть справа)
- Значения в кластерах могут быть схожи на границах кластеров
- Внутри сегмента однородность максимальная
- Между сегментами однородность минимальна

```
✓ [98] KMeans_ / 3724
0s
KMeans
0    0.246778
1    0.187433
2    0.193340
3    0.164608
4    0.207841
dtype: float64
```



Далее посмотрим на распределение данных внутри каждого из ПЯТИ кластеров: **на средние значения для количественных переменных и на медианные/наиболее часто встречающиеся для категориальных**, чтобы определить «тип» клиента в каждом сегменте.

Помним, что кластеры должны максимально различаться, поэтому, например, переменную Education включать описание не будем, поскольку она принимает одинаковое значение для всех кластеров: вероятнее всего, все наши клиенты имеют как минимум высшее образование, а возможно второе высшее или ученую степень. Аналогично клиенты в каждом сегменте, вероятнее всего, застрахованы.

Среднее (MEAN) каждой переменной в каждом из пяти кластеров (красным зачеркнуто среднее по категориальным переменным):

KMeans	0	1	2	3	4
INSURANCE_FLAG	0.60	0.58	0.60	0.63	0.60
DTI	0.38	0.40	0.40	0.37	0.40
SEX	0.51	0.58	0.30	0.32	0.71
FULL_AGE_CHILD_NUMBER	0.56	0.42	0.73	0.75	0.28
DEPENDANT_NUMBER	0.01	0.00	0.01	0.00	0.00
EDUCATION	5.10	5.18	4.00	5.33	5.04
BANKACCOUNT_FLAG	0.23	0.24	0.32	0.08	0.24
Period_at_work	49.91	56.55	78.87	59.57	42.43
age	35.48	34.14	38.12	39.46	33.47
max90days	1.70	1.42	1.53	1.65	1.57
max60days	1.16	0.99	1.09	1.21	1.06
max30days	0.86	0.69	0.76	0.80	0.75
max21days	0.64	0.51	0.57	0.59	0.53
max14days	0.52	0.39	0.46	0.48	0.43
avg_num_delay	0.07	0.05	0.05	0.06	0.07
if_zalog	0.31	0.16	0.40	0.60	0.13
num_AccountActive180	0.43	0.39	0.38	0.37	0.41
num_AccountActive90	0.17	0.18	0.19	0.15	0.18
num_AccountActive60	0.09	0.12	0.12	0.09	0.10
Active_to_All_prc	0.41	0.47	0.39	0.40	0.45
numAccountActiveAll	2.38	1.96	2.28	2.50	1.97
numAccountClosed	3.85	2.74	3.92	4.13	3.02
sum_of_paym_months	85.13	61.72	89.90	108.40	60.89
all_credits	6.23	4.70	6.20	6.62	5.00
Active_not_cc	1.21	0.91	1.15	1.25	0.94
own_closed	0.76	0.60	0.92	0.90	0.53
min_MnthAfterLoan	13.37	14.14	14.30	14.91	13.08
max_MnthAfterLoan	63.06	53.36	67.16	72.26	50.92
dlq_exist	0.63	0.45	0.53	0.67	0.53
thirty_in_a_year	0.10	0.00	0.12	0.17	0.15

KMeans	0	1	2	3	4
sixty_in_a_year	0.11	0.05	0.07	0.09	0.09
ninety_in_a_year	0.07	0.03	0.05	0.07	0.07
thirty_vintage	0.04	0.02	0.02	0.03	0.03
sixty_vintage	0.02	0.01	0.01	0.01	0.01
ninety_vintage	0.02	0.01	0.01	0.02	0.02
Форма банка (без печати работодателя)_INCOME_BASE_TYPE	0.25	0.74	0.44	0.09	0.17
Поступление зарплаты на счет_INCOME_BASE_TYPE	0.20	0.67	0.24	0.01	0.67
2НДФЛ_INCOME_BASE_TYPE	0.19	0.02	0.04	0.11	0.08
Свободная форма с печатью работодателя_INCOME_BASE_TYPE	0.36	0.06	0.28	0.78	0.07
Ремонт_CREDIT_PURPOSE	0.03	0.04	0.03	0.03	0.04
Лечение_CREDIT_PURPOSE	0.01	0.02	0.01	0.01	0.01
Покупка автомобиля_CREDIT_PURPOSE	0.01	0.01	0.01	0.01	0.02
Покупка недвижимости/ строительства_CREDIT_PURPOSE	0.04	0.06	0.04	0.05	0.05
Отпуск_CREDIT_PURPOSE	0.14	0.23	0.19	0.14	0.16
Покупка земли_CREDIT_PURPOSE	0.01	0.01	0.01	0.02	0.01
Покупка бытовой техники_CREDIT_PURPOSE	0.00	0.01	0.01	0.02	0.01
Покупка мебели_CREDIT_PURPOSE	0.02	0.02	0.03	0.02	0.02
Другое_CREDIT_PURPOSE	0.12	0.08	0.18	0.16	0.08
Обучение_CREDIT_PURPOSE	0.62	0.50	0.50	0.56	0.60
вспомогательный персонал_EMPL_TYPE	0.20	0.14	0.16	0.08	0.26
специалист_EMPL_TYPE	0.00	0.00	0.00	0.00	0.00
менеджер среднего звена_EMPL_TYPE	0.06	0.01	0.03	0.36	0.01
менеджер высшего звена_EMPL_TYPE	0.03	0.02	0.01	0.03	0.03
торговый представитель_EMPL_TYPE	0.29	0.13	0.25	0.32	0.16
рабочий_EMPL_TYPE	0.08	0.08	0.20	0.04	0.06
менеджер по продажам_EMPL_TYPE	0.31	0.59	0.33	0.15	0.44
страховой агент_EMPL_TYPE	0.00	0.00	0.00	0.00	0.00
другое_EMPL_TYPE	0.03	0.02	0.02	0.01	0.03
>250_EMPL_SIZE	0.26	0.02	0.11	0.88	0.02
< 50_EMPL_SIZE	0.74	0.98	0.89	0.12	0.98

KMeans	0	1	2	3	4
Торговля_EMPL_PROPERTY	0.08	0.63	0.83	0.22	0.01
Другое_EMPL_PROPERTY	0.04	0.20	0.10	0.05	0.07
Сельское и лесное хозяйство_EMPL_PROPERTY	0.01	0.01	0.03	0.01	0.00
Информационные технологии_EMPL_PROPERTY	0.86	0.75	0.03	0.70	0.92
Юридические услуги_EMPL_PROPERTY	0.01	0.01	0.01	0.02	0.00
ООО_EMPL_FORM	0.01	0.05	0.09	0.01	0.00
Иная форма_EMPL_FORM	0.10	0.24	0.21	0.04	0.10
ЗАО_EMPL_FORM	0.01	0.04	0.06	0.02	0.01
ОАО_EMPL_FORM	0.03	0.00	0.01	0.09	0.01
Индивидуальный предприниматель_EMPL_FORM	0.02	0.16	0.28	0.01	0.03
Государственное предприятие_EMPL_FORM	0.83	0.51	0.36	0.82	0.86
женат / замужем_FAMILY_STATUS	0.00	0.00	0.00	0.00	0.00
холост / не замужем_FAMILY_STATUS	0.06	0.05	0.02	0.03	0.05
разведен / разведена_FAMILY_STATUS	0.60	0.37	0.06	0.78	0.17
гражданский брак_FAMILY_STATUS	0.03	0.02	0.04	0.04	0.01
повторный брак_FAMILY_STATUS	0.06	0.07	0.04	0.04	0.07
вдовец / вдова_FAMILY_STATUS	0.25	0.49	0.04	0.11	0.69

Медианное значение (MEDIAN) каждой переменной в каждом из пяти кластеров (синим зачеркнуты медианные значения по количественным переменным):

KMeans	0	1	2	3	4
INSURANCE_FLAG	1.00	1.00	1.00	1.00	1.00
DTI	0.40	0.42	0.43	0.38	0.42
SEX	1.00	1.00	0.00	0.00	1.00
FULL_AGE_CHILD_NUMBER	0.00	0.00	1.00	1.00	0.00
DEPENDANT_NUMBER	0.00	0.00	0.00	0.00	0.00
EDUCATION	6.00	6.00	6.00	6.00	6.00
BANKACCOUNT_FLAG	0.00	0.00	0.00	0.00	0.00
Period_at_work	36.00	37.00	56.50	44.00	32.00
age	34.00	32.00	37.00	39.00	31.00
max90days	1.00	1.00	1.00	1.00	1.00
max60days	1.00	1.00	1.00	1.00	1.00
max30days	1.00	0.00	0.00	0.00	0.00
max21days	0.00	0.00	0.00	0.00	0.00
max14days	0.00	0.00	0.00	0.00	0.00
avg_num_delay	0.02	0.00	0.01	0.02	0.03
if_zalog	0.00	0.00	0.00	1.00	0.00
num_AccountActive180	0.00	0.00	0.00	0.00	0.00
num_AccountActive90	0.00	0.00	0.00	0.00	0.00
num_AccountActive60	0.00	0.00	0.00	0.00	0.00
Active_to_All_prc	0.38	0.44	0.37	0.33	0.43
numAccountActiveAll	2.00	2.00	2.00	2.00	2.00
numAccountClosed	3.00	2.00	3.00	3.00	2.00
sum_of_paym_months	70.00	47.00	71.00	87.00	43.00
all_credits	5.00	4.00	5.00	6.00	4.00
Active_not_cc	1.00	1.00	1.00	1.00	1.00
own_closed	0.00	0.00	0.00	1.00	0.00
min_MnthAfterLoan	9.00	9.00	10.00	11.00	8.00
max_MnthAfterLoan	70.00	51.50	72.00	79.00	45.50
dlq_exist	1.00	0.00	1.00	1.00	1.00
thirty_in_a_year	0.00	0.00	0.00	0.00	0.00

KMeans	0	1	2	3	4
sixty_in_a_year	0.0	0.0	0.0	0.0	0.0
ninety_in_a_year	0.0	0.0	0.0	0.0	0.0
thirty_vintage	0.0	0.0	0.0	0.0	0.0
sixty_vintage	0.0	0.0	0.0	0.0	0.0
ninety_vintage	0.0	0.0	0.0	0.0	0.0
Форма банка (без печати работодателя)_INCOME_BASE_TYPE	0.0	0.0	0.0	0.0	0.0
Поступление зарплаты на счет_INCOME_BASE_TYPE	0.0	1.0	0.0	0.0	1.0
2НДФЛ_INCOME_BASE_TYPE	0.0	0.0	0.0	0.0	0.0
Свободная форма с печатью работодателя_INCOME_BASE_TYPE	0.0	0.0	0.0	1.0	0.0
Ремонт_CREDIT_PURPOSE	0.0	0.0	0.0	0.0	0.0
Лечение_CREDIT_PURPOSE	0.0	0.0	0.0	0.0	0.0
Покупка автомобиля_CREDIT_PURPOSE	0.0	0.0	0.0	0.0	0.0
Покупка недвижимости/ строительство_CREDIT_PURPOSE	0.0	0.0	0.0	0.0	0.0
Отпуск_CREDIT_PURPOSE	0.0	0.0	0.0	0.0	0.0
Покупка земли_CREDIT_PURPOSE	0.0	0.0	0.0	0.0	0.0
Покупка бытовой техники_CREDIT_PURPOSE	0.0	0.0	0.0	0.0	0.0
Покупка мебели_CREDIT_PURPOSE	0.0	0.0	0.0	0.0	0.0
Другое_CREDIT_PURPOSE	0.0	0.0	0.0	0.0	0.0
Обучение_CREDIT_PURPOSE	1.0	1.0	0.0	1.0	1.0
вспомогательный персонал_EMPL_TYPE	0.0	0.0	0.0	0.0	0.0
специалист_EMPL_TYPE	0.0	0.0	0.0	0.0	0.0
менеджер среднего звена_EMPL_TYPE	0.0	0.0	0.0	0.0	0.0
менеджер высшего звена_EMPL_TYPE	0.0	0.0	0.0	0.0	0.0
торговый представитель_EMPL_TYPE	0.0	0.0	0.0	0.0	0.0
рабочий_EMPL_TYPE	0.0	0.0	0.0	0.0	0.0
менеджер по продажам_EMPL_TYPE	0.0	1.0	0.0	0.0	0.0
страховой агент_EMPL_TYPE	0.0	0.0	0.0	0.0	0.0
другое_EMPL_TYPE	0.0	0.0	0.0	0.0	0.0
>250_EMPL_SIZE	0.0	0.0	0.0	1.0	0.0
< 50 EMPL SIZE	1.0	1.0	1.0	0.0	1.0

KMeans	0	1	2	3	4
Торговля_EMPL_PROPERTY	0.0	1.0	1.0	0.0	0.0
Другое_EMPL_PROPERTY	0.0	0.0	0.0	0.0	0.0
Сельское и лесное хозяйство_EMPL_PROPERTY	0.0	0.0	0.0	0.0	0.0
Информационные технологии_EMPL_PROPERTY	1.0	0.0	0.0	1.0	1.0
Юридические услуги_EMPL_PROPERTY	0.0	0.0	0.0	0.0	0.0
ООО_EMPL_FORM	0.0	0.0	0.0	0.0	0.0
Иная форма_EMPL_FORM	0.0	0.0	0.0	0.0	0.0
ЗАО_EMPL_FORM	0.0	0.0	0.0	0.0	0.0
ОАО_EMPL_FORM	0.0	0.0	0.0	0.0	0.0
Индивидуальный предприниматель_EMPL_FORM	0.0	0.0	0.0	0.0	0.0
Государственное предприятие_EMPL_FORM	1.0	1.0	0.0	1.0	1.0
женат / замужем_FAMILY_STATUS	0.0	0.0	0.0	0.0	0.0
холост / не замужем_FAMILY_STATUS	0.0	0.0	0.0	0.0	0.0
разведен / разведена_FAMILY_STATUS	1.0	0.0	1.0	1.0	0.0
гражданский брак_FAMILY_STATUS	0.0	0.0	0.0	0.0	0.0
повторный брак_FAMILY_STATUS	0.0	0.0	0.0	0.0	0.0
вдовец / вдова_FAMILY_STATUS	0.0	0.0	0.0	0.0	1.0

Далее опишем полученные сегменты:

I. КЛАСТЕР 1

« Мать-одиночка »

Женщина 35 лет

Семейное положение: разведена

Вероятнее всего, имеющая ребенка

Работающая в IT на государственной службе
(гос предприятие)

Получающая **зп в размере менее 50 тыс./месяц**

Берущая кредит на обучение

Уже просрочившая кредит и имевшая более 5-6 кредитов

Оформившая кредит БЕЗ залога



ВЫВОДЫ ПО СЕГМЕНТУ

Клиенты в данном сегменте:

- Работоспособные
- С постоянным заработком (т.к. госслужба)
- С невысоким заработком
- С высокой вероятностью возьмут кредит еще раз
- С высокой вероятностью просрочат платежи по нему
- Берут кредит на обучение, то есть могут переквалифицироваться, увеличить свой заработок и приносить больше прибыли

II. КЛАСТЕР 2

« Карьеристка »

Женщина

Скорее всего **БЕЗ** ребенка

Живущая однозначно **без** иждивенцев в семье

Проработавшая почти 2 месяца на новом месте

Работающая менеджером по продажам в сфере торговли

Получающая **зп в размере менее 50 тыс./месяц на счет**

НЕ ИМЕЮЩАЯ ПРОСРОЧЕК

Имеющая больше закрытых счетов, чем открытых

Берущая кредит на обучение, имевшая более 5-6 кредитов. Оформившая кредит БЕЗ залога



ВЫВОДЫ ПО СЕГМЕНТУ

Клиенты в данном сегменте:

- Работоспособные карьеристки
- Без семьи и нацелены на построение карьеры, устроившиеся на новом месте
- С невысоким заработком, но стремятся переквалифицироваться
- Аккуратны, следят за кредитной историей и не имеют просрочек по платежам
- На данный момент стоит простимулировать их открывать новые счета, так как имеют перспективу увеличения зарплаты.

III. КЛАСТЕР 3

« Работяга »

Мужчина 38 лет

Семейное положение: разведен

Имеющий ребенка и иждивенцев в семье

Проработавший почти 3 месяца на новом месте (сильно больше всех клиентов в других кластерах)

Получающая **зп в размере менее 50 тыс./месяц**

Берущая кредит на обучение

Уже просрочивший кредит и имевший более 5 кредитов

Имеющий большую долю закрытых кредитов

Оформившая кредит БЕЗ залога



ВЫВОДЫ ПО СЕГМЕНТУ

Клиенты в данном сегменте:

- **Очень работоспособны**
- **Отличаются тем, что могут долго проработать на новом месте**
- **Отличаются надежностью: могут просрочить платежи, но все равно выплатят кредит**
- **С высокой вероятностью возьмут кредит еще раз**

IV. КЛАСТЕР 4

**« Надежный клиент,
квалифицированный
сотрудник »**

Мужчина 40 лет

Семейное положение: разведен, есть ребенок

Работающий в IT

Проработавший более 2х месяцев на новом месте

Получающий зп в размере более 250 тыс./месяц в
свободной форме с печатью работодателя

Имевший больше всего кредитов среди всех клиентов
в других кластерах

Уже просрочивший кредит, однако с высокой долей
закрытых кредитов

Оформивший кредит С ЗАЛОГОМ (в отличие от клиентов
в других кластерах)

Больше закрытых, чем открытых счетов



ВЫВОДЫ ПО СЕГМЕНТУ

Клиенты в данном сегменте:

- Квалифицированные специалисты
- С постоянным высоким уровнем заработка
- Берут много кредитов
- Готовы оставить залог
- Хорошая кредитная история: возвращают 91% кредитов, однако могут просрочить
- Скорее всего возьмут кредит еще раз
- Нужно стимулировать их открывать больше счетов и брать кредиты больших размеров

V. КЛАСТЕР 5

« Вдова »

Женщина 33 года

Семейное положение: **вдова**, нет ребенка

Работающая в IT на государственной службе (гос предприятие)

Проработавшая меньше всех на новом рабочем месте

Имеющая **наименьшую сумму платежей за последний месяц**

Получающая **зп в размере менее 50 тыс./месяц на счет**

Берущая кредит на обучение

Уже просрочившая кредит и имевшая около 5 кредитов

Оформившая кредит БЕЗ залога



ВЫВОДЫ ПО СЕГМЕНТУ

(схож с первым кластером)

Клиенты в данном сегменте:

- **ВДОВЫ, начинающие новую жизнь после утраты**
- **Работоспособные**
- **С постоянным заработком (т.к. госслужба)**
- **С невысоким заработком**
- **С высокой вероятностью возьмут кредит еще раз**
- **С высокой вероятностью просрочат платежи по нему**
- **Берут кредит на обучение, могут переквалифицироваться, увеличить свой заработок и приносить больше прибыли**

Мы можем заметить, что выделение 5 вместо трех кластеров не дало нам необходимой детализации, а скорее выделило 2 ненужных (лишних) сегмента. Сегмент «вдова» чрезмерно напоминает самый первый сегмент «мать-одиночка», а также второй «карьеристка». Кластеры 2 («карьеристка») и 3 («работяга») отличаются по большей части только полом.

Большинство наших клиентов

- разведены,
- оформляют кредиты БЕЗ залога,
- имеют просрочки по кредитам,
- берут кредит на обучение,
- ранее уже брали кредиты,
- получают низкую зарплату (менее 50к в месяц),
- работают на государственной основе.

Сегментация без учителя при помощи k-means дала спорные результаты. Тем не менее были успешно выделены несколько сегментов:

« Мать-одиночка » / « Вдова »

« Карьеристка » / « Работяга »

« Надежный клиент, квалифицированный сотрудник »

Часть 2: Сегментация

~~Метод 2: Сегментация с учителем. Дерево решений~~

Изначально было проведено исследование и построена сегментация в системе SAS, однако в связи с тем, что зайти в систему невозможно, результаты оказались потеряны 😞

Метод 2: Квантили (RFM-анализ)

В результате RFM-анализа мы поделим клиентов на сегменты в зависимости от трех показателей: Recency, Frequency и Monetary:

- Recency — разница между текущей датой и датой последнего платежа (давность)
- Frequency — количество транзакций (частота покупок)
- Monetary — сумма платежей

Далее каждому из трех показателей мы проставим баллы от 1 до 5 с использованием квантилей. Сортируем данные по одному из критериев и делим на равные группы.


Преимущества метода:

- Четко отражает сегменты на основе выбранных показателей
- Легко выполнить и интерпретировать
- Можно выявить «самых-самых»: покупающих больше всех, чаще всех и не покупавших дольше всех.

Недостатки:

- Неприменим для прогнозного сегментирования, однако в данном случае нам нет необходимости строить прогноз.

Чтобы выбрать оптимальное сочетание, мы исследовали показатели на корреляцию:



В результате были выбраны следующие показатели:

- **Recency = min_MnthAfterLoan** (минимальное кол-во месяцев, которое прошло с момента взятия прошлого кредита, то есть как давно выдали последний кредит клиенту)
- **Frequency = all credits** (Кол-во кредитов)
- **Monetary = sum_of_paym_months** (сумма платежей за последний месяц (тыс.))

Посмотрим на среднее и разброс значений у выбранных переменных:

	mean	min	max
min_MnthAfterLoan	14.0	-1.0	110.0
all_credits	6.0	1.0	37.0
sum_of_paym_months	81.0	0.0	793.0

Переменные даны в пригодном для использования формате, поэтому при построении RFM-квантилей не потребуются дополнительные преобразования.

Минимальное значение у переменной **min_MnthAfterLoan**, то есть минимальное значение минимального количества месяцев с момента взятия последнего кредита равно -1. Это может означать, что такие клиенты оформили кредит, начиная со следующего месяца. То есть со следующего месяца данная переменная станет равняться нулю, с последующего 1 и так далее.

Наши переменные имеют довольно большой разброс, поэтому нам лучше разбить данные не на 3, а на 5 сегментов, чтобы повысить детализацию в сегментах. Проставляем оценки от 1-5 каждой из переменных.


- Сегмент 1: лучшие клиенты, вносящие наибольшие суммы недавно и по наибольшему кол-ву кредитов. Основная задача: **удержание**
- Сегмент 2: хорошие постоянные клиенты, приносящие прибыль. Основная задача: **удержание**
- Сегмент 3: среднестатистическая **основная** клиентская база (средняя давность, частота и размер платежей), которую нужно **удержать + стимулировать на еще большие платежи/кредиты**
- Сегмент 4: практически потерянные, спящие клиенты, при наличии ресурсов и должном анализе и переоценке причин спячки клиентов, их возможно **вернуть**
- Сегмент 5: однозначно **потерянные клиенты**, на привлечение которые (скорее всего) не имеет смысла тратить ресурсы

	5	4	3	2	1
min_MnthAfterLoan	ОЧЕНЬ ДАВНО Наиболее потерянные, давние клиенты.	ДАВНО Почти потерянные клиенты, бравшие кредит весьма давно, спящие давние.	НЕ ТАК ДАВНО Брали кредит относительно недавно, но какое-то время уже прошло, но не окончательно потеряны, спящие.	НЕДАВНО Эти клиенты брали кредит недавно, все еще находятся в списке активных клиентов.	ТОЛЬКО ЧТО Последний кредит был взят только что, прошло совсем мало времени (здесь же случай с -1, то есть кредит выдан как бы со след месяца.
all_credits	ОЧЕНЬ РЕДКО/ РАЗОВО Клиенты, взявшие очень мало кредитов, в том числе пришедшие разово.	РЕДКО Клиенты, взявшие всего несколько кредитов, но вернувшиеся после первого (не разово).	ДОСТАТОЧНО ЧАСТО Клиенты, взявшие некоторое среднее количество кредитов (более 5). Скорее всего вернуться.	ЧАСТО Клиенты, взявшие приличное количество кредитов. Ожидаем, что придут и возьмут еще.	ОЧЕНЬ ЧАСТО Клиенты, взявшие наибольшее количество кредитов. Почти точно придут и возьмут еще.
sum_of_paym_months	ОЧЕНЬ МАЛО Не платили ни разу или платили очень мало. Крайне низкая сумма платежей за последний месяц.	МАЛО Практически не платили в последний месяц.	НЕ ОЧЕНЬ МНОГО Платили, но не много. В будущем еще могут заплатить.	МНОГО Внесли приличную сумму в последний месяц.	ОЧЕНЬ МНОГО Наиболее платежеспособные клиенты за последний месяц.

В совокупности мы получим 125 сегментов ($5*5*5$), где сочетание цифр 111 будет показывать наиболее перспективного клиента, а сочетание 555 – наименее перспективного.

Приведенный ниже график показывает среднее значение переменной гесепсу, то есть минимального числа месяцев с последнего платежа по всем RFMScore.

Мы видим, что четким образом выделились 5 сегментов. При чем в 5 сегменте наиболее неоднородные показатели.



Посмотрим на каждый из проиллюстрированных графике сегментов по отдельности.

ПЕРВЫЙ СЕГМЕНТ

В первом сегменте должны находиться **лучшие клиенты**, вносящие **наибольшие суммы**, **недавно** и по **наибольшему кол-ву кредитов**.

Мы видим, что модальное значение RFM = 155. Это означает, что клиенты в данном сегменте являются весьма перспективными, поскольку больше всего раз в данном сегменте встречается оценка, в которой 2 из 3 показателей равны 5. Этим клиентов **важно удерживать**.

Типичный клиент в этом сегменте скорее всего:

- Женщина 36 лет
- Получающая зарплату в размере более 250 тыс./месяц на счет
- Берущая кредит на ремонт
- Последний раз бравшая кредит **2 месяца назад**
- Имеющая в среднем **7 кредитов**
- Заплатившая **82 тыс.руб.** за последний месяц

```
MEAN
ID                1104263.0
recency           2.0
frequency         7.0
monetary          82.0
r_quartile        1.0
f_quartile        3.0
m_quartile        3.0
RFMScore          inf
age              36.0
dtype: float64
```

```
MODE
ID                1000179
recency           2.0
frequency         4.0
monetary          1.0
r_quartile        1.0
f_quartile        4.0
m_quartile        3.0
RFMScore          155
SEX               женский
INCOME_BASE_TYPE  Поступление зарплаты на счет
CREDIT_PURPOSE    Ремонт
EMPL_TYPE         специалист
EMPL_SIZE         >250
age              28.0
Name: 0, dtype: object
```

{ '112', '153', '141', '155', '114', '131', '124', '132', '134', '113', '142', '122', '121', '143', '111', '123', '144', '154', '135', '152', '133', '145' }													
	ID	recency	frequency	monetary	r_quartile	f_quartile	m_quartile	RFMScore	SEX	INCOME_BASE_TYPE	CREDIT_PURPOSE	EMPL_TYPE	EMPL_SIZE
3	1000179	1	6	108	1	3	4	134	мужской	Поступление зарплаты на счет	Ремонт	менеджер среднего звена	>250
4	1000199	1	2	92	1	1	4	114	мужской	Поступление зарплаты на счет	Покупка автомобиля	специалист	>250
15	1000899	1	4	112	1	2	4	124	женский	Форма банка (без печати работодателя)	Ремонт	менеджер среднего звена	< 50
30	1001999	0	5	60	1	3	3	133	мужской	Форма банка (без печати работодателя)	Ремонт	менеджер высшего звена	>250
32	1002119	0	14	239	1	5	5	155	мужской	2НДФЛ	Ремонт	менеджер высшего звена	< 50
...	...	...	...	...	...	...	...	...	...	...	...	...	...
3701	1203379	2	8	62	1	4	3	143	мужской	Свободная форма с печатью работодателя	Ремонт	менеджер среднего звена	>250
3702	1203459	3	9	112	1	4	4	144	женский	Форма банка (без печати работодателя)	Покупка автомобиля	менеджер среднего звена	< 50
3712	1203959	2	7	80	1	4	4	144	женский	Свободная форма с печатью работодателя	Ремонт	специалист	< 50
3713	1203999	1	7	39	1	4	2	142	женский	Свободная форма с печатью работодателя	Ремонт	специалист	>250
3722	1204779	3	2	14	1	1	1	111	мужской	Поступление зарплаты на счет	Ремонт	специалист	>250
807 rows × 13 columns													

ВТОРОЙ СЕГМЕНТ

Во втором сегменте находятся **довольно перспективные клиенты**.

Модальное значение RFM = 255. Это означает, что клиенты в данном сегменте являются довольно перспективными, поскольку больше всего раз в данном сегменте встречается оценка, в которой 2 из 3 показателей равны 5. Также заметим, что клиенты во втором сегменте несмотря на то, что отстают от первого по показателю ресенсу по размерам платежей превышают клиентов в первом сегменте. Этих клиентов также **необходимо удерживать**.

Типичный клиент в этом сегменте слабо отличается от первого сегмента:

- Женщина 35 лет
- Получающая зарплату в размере более 250 тыс./месяц на счет
- Берущая кредит на ремонт
- Последний раз бравшая кредит 5 месяца назад
- Имеющая в среднем 7 кредитов
- Заплатившая 91 тыс.руб. за последний месяц

MEAN	
ID	1098074.0
recency	5.0
frequency	7.0
monetary	91.0
r_quartile	2.0
f_quartile	3.0
m_quartile	3.0
RFMScore	inf
age	35.0
dtype:	float64

MODE	
ID	1000139
recency	4.0
frequency	4.0
monetary	5.0
r_quartile	2.0
f_quartile	5.0
m_quartile	5.0
RFMScore	255
SEX	женский
INCOME_BASE_TYPE	Поступление зарплаты на счет
CREDIT_PURPOSE	Ремонт
EMPL_TYPE	специалист
EMPL_SIZE	>250
age	26.0
Name:	0, dtype: object

{ '231', '212', '252', '244', '222', '243', '213', '224', '255', '211', '242', '234', '253', '232', '214', '221', '225', '235', '223', '245', '233', '254' }														
	ID	recency	frequency	monetary	r_quartile	f_quartile	m_quartile	RFMScore	SEX	INCOME_BASE_TYPE	CREDIT_PURPOSE	EMPL_TYPE	EMPL_SIZE	age
2	1000139	4	7	76	2	4	3	243	мужской	Форма банка (без печати работодателя)	Лечение	специалист	< 50	47
6	1000299	6	12	207	2	5	5	255	мужской	Поступление зарплаты на счет	Покупка недвижимости/ строительство	менеджер высшего звена	>250	54
8	1000359	6	9	76	2	4	3	243	женский	2НДФЛ	Ремонт	специалист	>250	35
10	1000559	6	14	122	2	5	4	254	мужской	2НДФЛ	Покупка автомобиля	специалист	>250	26
13	1000759	4	8	82	2	4	4	244	мужской	Поступление зарплаты на счет	Покупка автомобиля	торговый представитель	>250	26
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
3714	1204039	4	11	85	2	5	4	254	женский	Форма банка (без печати работодателя)	Ремонт	специалист	>250	25
3717	1204379	5	3	36	2	2	2	222	женский	2НДФЛ	Покупка автомобиля	специалист	>250	31
3720	1204639	5	23	403	2	5	5	255	мужской	Форма банка (без печати работодателя)	Покупка недвижимости/ строительство	менеджер среднего звена	>250	27
3721	1204719	6	12	162	2	5	5	255	женский	Поступление зарплаты на счет	Ремонт	специалист	>250	27
3723	1204839	6	17	205	2	5	5	255	женский	2НДФЛ	Ремонт	специалист	>250	51
756 rows x 14 columns														

ТРЕТИЙ СЕГМЕНТ

В третьем сегменте находится **основная среднестатистическая клиентская база**.

Модальное значение RFM = 311. Это означает, что несмотря на среднее значение одного из показателей, два других находятся на минимальном уровне. Клиенты в данном сегменте довольно потерянные. Необходимо привлекать и стимулировать их на совершение новых сделок.

Типичный клиент в этом сегменте скорее всего:

- Мужчина 36 лет
- Получающий зарплату в размере более 250 тыс./месяц на счет
- Берущий кредит на ремонт
- Последний раз бравший кредит 10 месяцев назад
- Имеющий в среднем 6 кредитов
- Заплатившая 82 тыс.руб. за последний месяц

```
MEAN
ID          1098376.0
recency      10.0
frequency     6.0
monetary     82.0
r_quartile    3.0
f_quartile    3.0
m_quartile    3.0
RFMScore     inf
age          36.0
dtype: float64
```

```
MODE
ID          1000219
recency      8.0
frequency     5.0
monetary     10.0
r_quartile    3.0
f_quartile     2.0
m_quartile    3.0
RFMScore     311
SEX          мужской
INCOME_BASE_TYPE Поступление зарплаты на счет
CREDIT_PURPOSE      Ремонт
EMPL_TYPE          специалист
EMPL_SIZE         >250
age              27.0
Name: 0, dtype: object
```

{ '313', '335', '342', '345', '324', '323', '332', '325', '334', '311', '344', '321', '312', '353', '333', '355', '322', '343', '314', '331', '354' }														
	ID	recency	frequency	monetary	r_quartile	f_quartile	m_quartile	RFMScore	SEX	INCOME_BASE_TYPE	CREDIT_PURPOSE	EMPL_TYPE	EMPL_SIZE	age
5	1000219	10	5	50	3	3	3	333	мужской	Поступление зарплаты на счет	Ремонт	специалист	>250	26
19	1001239	10	9	209	3	4	5	345	женский	Поступление зарплаты на счет	Ремонт	специалист	>250	39
28	1001799	8	9	76	3	4	3	343	мужской	Поступление зарплаты на счет	Ремонт	торговый представитель	>250	30
33	1002159	8	5	36	3	3	2	332	женский	Поступление зарплаты на счет	Ремонт	специалист	>250	32
37	1002339	8	6	135	3	3	5	335	мужской	Форма банка (без печати работодателя)	Ремонт	менеджер среднего звена	>250	44
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
3692	1202999	10	7	133	3	4	5	345	мужской	Форма банка (без печати работодателя)	Ремонт	специалист	>250	33
3696	1203099	12	9	190	3	4	5	345	мужской	Свободная форма с печатью работодателя	Ремонт	вспомогательный персонал	>250	45
3704	1203539	10	1	11	3	1	1	311	женский	2НДФЛ	Ремонт	вспомогательный персонал	>250	48
3708	1203699	12	6	78	3	3	3	333	мужской	Свободная форма с печатью работодателя	Ремонт	специалист	>250	28
3719	1204599	12	5	70	3	3	3	333	мужской	2НДФЛ	Покупка автомобиля	вспомогательный персонал	>250	31
732 rows × 14 columns														

ЧЕТВЁРТЫЙ СЕГМЕНТ

Во четвертом сегменте должны находиться «спящие» клиенты.

Модальное значение RFM = 411. Это означает, что несмотря на довольно высокое значение одного из показателей (4), два других находятся на минимальном уровне. Клиенты в данном сегменте весьма потерянные или же «спящие». Необходимо привлекать и стимулировать их на открытие новых кредитных счетов.

Типичный клиент в этом сегменте скорее всего:

- Мужчина 36 лет
- Получающий зарплату в размере более 250 тыс./месяц в форме банка (без печати работодателя)
- Берущий кредит на ремонт
- Последний раз бравший кредит **16 месяцев назад**
- Имеющий в среднем 5 кредитов
- Заплативший 80 тыс.руб. за последний месяц

MEAN	
ID	1097045.0
recency	16.0
frequency	5.0
monetary	80.0
r_quartile	4.0
f_quartile	3.0
m_quartile	3.0
RFMScore	inf
age	36.0
dtype: float64	

MODE	
ID	1000079
recency	13.0
frequency	2.0
monetary	16.0
r_quartile	4.0
f_quartile	2.0
m_quartile	5.0
RFMScore	411
SEX	мужской
INCOME_BASE_TYPE	Форма банка (без печати работодателя)
CREDIT_PURPOSE	Ремонт
EMPL_TYPE	специалист
EMPL_SIZE	>250
age	33.0
Name: 0, dtype: object	

{ '423', '455', '414', '424', '445', '431', '433', '411', '432', '421', '434', '443', '425', '453', '413', '441', '422', '435', '444', '454', '412' }															
	ID	recency	frequency	monetary	r_quartile	f_quartile	m_quartile	RFMScore	SEX	INCOME_BASE_TYPE		CREDIT_PURPOSE	EMPL_TYPE	EMPL_SIZE	age
1	1000079	18	5	79	4	3	4	434	женский	Поступление зарплаты на счет		Ремонт	специалист	>250	43
11	1000639	17	4	53	4	2	3	423	женский	Поступление зарплаты на счет		Покупка недвижимости/ строительство	специалист	>250	46
12	1000679	17	19	349	4	5	5	455	мужской	Форма банка (без печати работодателя)		Ремонт	вспомогательный персонал	< 50	44
14	1000879	15	7	61	4	4	3	443	мужской	2НДФЛ		Покупка автомобиля	рабочий	>250	33
17	1000959	15	2	21	4	1	1	411	женский	Поступление зарплаты на счет		Покупка автомобиля	рабочий	>250	28
...	...	...	...	...	...	...	...	...	...	...		...	...	...	...
3686	1202719	13	5	106	4	3	4	434	мужской	2НДФЛ		Покупка недвижимости/ строительство	специалист	>250	55
3706	1203619	21	5	70	4	3	3	433	женский	Форма банка (без печати работодателя)		Ремонт	специалист	< 50	32
3709	1203719	18	6	165	4	3	5	435	мужской	Форма банка (без печати работодателя)		Ремонт	специалист	< 50	42
3710	1203839	18	13	175	4	5	5	455	женский	Поступление зарплаты на счет		Покупка автомобиля	менеджер среднего звена	>250	34
3715	1204059	15	2	26	4	1	2	412	женский	Форма банка (без печати работодателя)		Ремонт	специалист	>250	36
696 rows x 14 columns															

ПЯТЫЙ СЕГМЕНТ

В последнем пятом сегменте находятся клиенты **наиболее потерянные и наименее перспективные**.

Однако мы видим, что модальное значение RFM = 511. Это означает, что несмотря на наиболее высокую оценку одного из показателей (5), в данном сегменте наиболее часто встречаются минимальные значения по двум другим показателям. Клиенты в данном сегменте потеряны: **не брали кредит в среднем более 3 лет, имеют наименьшее количество кредитов среди всех клиентов**, а также вносили **наименьшую сумму платежей за последний месяц**.

Однако (!) в среднем клиенты в этом сегменте **брали кредит более чем разово**, значит могут быть не однозначно потеряно. Но, вероятнее всего, не стоит тратить средства на привлечение и удержание этих клиентов.

Типичный клиент в этом сегменте скорее всего:

- Мужчина 38 лет
- Получающий зарплату в размере более 250 тыс./месяц на счет
- Берущий кредит на ремонт
- Последний раз бравший кредит 38 месяцев назад
- Имеющий в среднем 3 кредита
- Заплативший 67 тыс.руб. за последний месяц

```
MEAN
ID          1091314.0
recency      38.0
frequency     3.0
monetary     67.0
r_quartile    5.0
f_quartile    2.0
m_quartile    3.0
RFMScore      inf
age          38.0
dtype: float64
```

```
MODE
ID          1000059
recency      22.0
frequency     2.0
monetary     22.0
r_quartile    5.0
f_quartile    1.0
m_quartile    2.0
RFMScore     511
SEX          мужской
INCOME_BASE_TYPE Поступление зарплаты на счет
CREDIT_PURPOSE      Ремонт
EMPL_TYPE          специалист
EMPL_SIZE         >250
age              31.0
Name: 0, dtype: object
```

{ '544', '513', '521', '543', '533', '512', '532', '515', '545', '535', '524', '522', '542', '514', '511', '534', '555', '554', '525', '523' }														
	ID	recency	frequency	monetary	r_quartile	f_quartile	m_quartile	RFMScore	SEX	INCOME_BASE_TYPE	CREDIT_PURPOSE	EMPL_TYPE	EMPL_SIZE	age
0	1000059	26	4	81	5	2	4	524	женский	Форма банка (без печати работодателя)	Ремонт	вспомогательный персонал	>250	29
7	1000319	65	1	46	5	1	2	512	мужской	Форма банка (без печати работодателя)	Покупка автомобиля	специалист	>250	45
9	1000439	35	3	63	5	2	3	523	женский	Форма банка (без печати работодателя)	Ремонт	специалист	>250	35
16	1000919	30	4	147	5	2	5	525	мужской	Форма банка (без печати работодателя)	Ремонт	специалист	< 50	57
18	1001059	22	10	112	5	5	4	554	женский	Форма банка (без печати работодателя)	Ремонт	специалист	< 50	41
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
3693	1203019	23	2	26	5	1	2	512	женский	Поступление зарплаты на счет	Покупка недвижимости/ строительство	вспомогательный персонал	>250	28
3698	1203319	40	1	15	5	1	1	511	мужской	Поступление зарплаты на счет	Покупка недвижимости/ строительство	рабочий	>250	51
3703	1203499	99	1	99	5	1	4	514	мужской	Поступление зарплаты на счет	Ремонт	вспомогательный персонал	>250	32
3716	1204179	27	4	94	5	2	4	524	женский	Поступление зарплаты на счет	Ремонт	вспомогательный персонал	>250	36
3718	1204499	33	4	27	5	2	2	522	женский	2НДФЛ	Покупка недвижимости/ строительство	специалист	>250	31
733 rows x 14 columns														

Выводы из RFM-сегментации:

- **Наиболее прибыльные клиенты** находятся в первом и втором сегментах.

Основная цель: удержание этих клиентов.

Возможные способы: персональные предложения, членские скидки

- Наименее прибыльные/потерянные клиенты находятся в 4 и 5 сегментах. Однако есть вероятность, что они потеряны не окончательно и относятся к «спящим клиентам».

Основная цель: попытаться разбудить

Общие выводы из сегментации:

- Сегменты получились разнородны, однако местами схожи между собой в обоих случаях. Вероятно, проблема в том, что для наших данных разбиение на более 3 сегментов излишне и вместо детализации стимулирует возникновение похожих сегментов.
- Несмотря на то, что многие сегменты RFM действительно похожи на сегменты полученные с помощью кластеризации k-means, некоторые показатели, такие как цель кредита, пол внутри кластеров или уровень зарплаты – отличаются.

Приложение (Часть 1)

1) Первичный анализ данных: проверка на нулевые и уникальные, а также некорректные значения осуществлялся в системе SAS:

Column	Unique	Null	Mean	Median	Mode	Standard Deviation	Standard Error	Minimum	Maximum	Data T...	Act...	Data Length	Minim...	Maxim...
⊕ Active_not_cc	0.21% (8)	63.49%...	1.09	1.00	1.00	1.08	0.02	0.00	8.00	double		8		
⊕ Active_to All...	2.59% (97)	63.49%...	0.42	0.40	0.50	0.29	0.00	0.00	1.00	double		8		
⊕ BANKACCOU...	0.05% (4)	22.78% (2...	0.38	0.00	0.00	0.87	0.01	0.00	4.00	double		8		
⊕ CREDIT PURP...	0.10% (10)				Ремонт			Другое	Ремонт	varchar	string	67	12	67
⊕ DEPENDANT...	0.04% (4)		0.00	0.00	0.00	0.09	0.00	0.00	3.00	double		8		
⊕ DTI	0.59% (60)	1.03% (106)	0.39	0.41	0.59	0.14	0.00	0.01	0.63	double		8		
⊕ EDUCATION	0.09% (9)	0.01% (1)			высшее			*н.а.*	ученая степень	varchar	string	66	6	66
⊕ EMPL FORM	0.15% (6)	60.94...			ООО			Государственное предприятие	ООО	varchar	string	59	6	59
⊕ EMPL PROPE...	0.15% (12)	22.78% (2...			Торговля			Государственная служба	Юридические услуги	varchar	string	51	10	51

Column	Unique	Null	Mean	Median	Mode	Standard Deviation	Standard Error	Minimum	Maximum	Data T...	Act...	Data Length	Minim...	Maxim...
⊕ EMPL SIZE	0.08% (8)	1.03% (105)			>250			*н.а.*	>=50	varchar	string	6	4	6
⊕ EMPL TYPE	0.09% (9)	0.10% (10)			специалист			вспомогательный персонал	торговый предста...	varchar	string	47	12	47
⊕ FAMILY STATUS	0.15% (6)	60.94...			женат / з...			вдовец / вдова	холост / не замужем	varchar	string	37	25	37
⊕ FULL AGE C...	0.06% (6)	0.02% (2)	0.56	0.00	0.00	0.76	0.01	0.00	5.00	double		8		
⊕ ID	100.00% (10...		1,10...	1,10...		59,135.10	584.32	1,000,019.00	1,204,839.00	double		8		
⊕ INCOME BAS...	0.04% (4)	0.71% (73)			2НДФЛ			2НДФЛ	Форма банка (без ...	varchar	string	72	9	72
⊕ INSURANCE...	0.02% (2)	0.01% (1)	0.61	1.00	1.00	0.49	0.00	0.00	1.00	double		8		
⊕ Period at work	4.59% (363)	22.78% (2...	65.96	44.00	6.00	65.96	0.74	5.00	481.00	double		8		
⊕ SEX	0.02% (2)				мужской			женский	мужской	varchar	string	14	14	14

Column	Unique	Null	Mean	Median	Mode	Standard Deviation	Standard Error	Minimum	Maximum	Data T...	Act...	Data Length	Minim...	Maxim...	Ordina...
⊕ age	0.51% (40)	22.78% (2...)	36.28	35.00	26.00	8.67	0.10	23.00	62.00	double		8			15
⊕ all_credits	0.80% (30)	63.49%...	5.75	5.00	2.00	4.12	0.07	1.00	37.00	double		8			33
⊕ avg_num_delay	31.30%	63.59%...	0.06	0.01	0.00	0.11	0.00	0.00	0.97	double		8			24
⊕ dlq_exist	0.05% (2)	63.49%...	0.56	1.00	1.00	0.50	0.01	0.00	1.00	double		8			38
⊕ if_zalog	0.05% (2)	63.49%...	0.32	0.00	0.00	0.47	0.01	0.00	1.00	double		8			25
⊕ max14days	0.35% (14)	61.30%...	0.51	0.00	0.00	0.99	0.02	0.00	16.00	double		8			23
⊕ max21days	0.35% (14)	61.30%...	0.61	0.00	0.00	1.10	0.02	0.00	16.00	double		8			22
⊕ max30days	0.38% (15)	61.30%...	0.81	0.00	0.00	1.27	0.02	0.00	21.00	double		8			21
⊕ max60days	0.43% (17)	61.30%...	1.12	1.00	0.00	1.53	0.02	0.00	22.00	double		8			20
⊕ max90days	0.48% (19)	61.30%...	1.58	1.00	1.00	1.83	0.03	0.00	23.00	double		8			19
Column	Unique	Null	Mean	Median	Mode	Standard Deviation	Standard Error	Minimum	Maximum	Data T...	Act...	Data Length	Minim...	Maxim...	Ordina...
⊕ max_MnthAfr...	3.56% (133)	63.49%...	61.07	66.00	80.00	31.24	0.51	0.00	416.00	double		8			37
⊕ min_MnthAfte...	2.57% (96)	63.49%...	13.89	9.00	2.00	15.07	0.25	-1.00	110.00	double		8			36
⊕ ninety_in_a_y...	0.05% (2)	63.49%...	0.06	0.00	0.00	0.24	0.00	0.00	1.00	double		8			41
⊕ ninety_vintage	0.05% (2)	63.49%...	0.02	0.00	0.00	0.12	0.00	0.00	1.00	double		8			44
⊕ numAccount...	0.35% (13)	63.49%...	2.22	2.00	1.00	1.70	0.03	0.00	12.00	double		8			30
⊕ numAccount...	0.67% (25)	63.49%...	3.54	3.00	1.00	3.24	0.05	0.00	31.00	double		8			31
⊕ num_Account...	0.19% (7)	63.49%...	0.40	0.00	0.00	0.71	0.01	0.00	6.00	double		8			26
⊕ num_Account...	0.11% (4)	63.49%...	0.10	0.00	0.00	0.36	0.01	0.00	3.00	double		8			28
⊕ num_Account...	0.13% (5)	63.49%...	0.18	0.00	0.00	0.46	0.01	0.00	4.00	double		8			27
Column	Unique	Null	Mean	Median	Mode	Standard Deviation	Standard Error	Minimum	Maximum	Data T...	Act...	Data Length	Minim...	Maxim...	Ordina...
⊕ num_Account...	0.17% (7)	63.49%...	0.40	0.00	0.00	0.71	0.01	0.00	6.00	double		8			26
⊕ num_Account...	0.11% (4)	63.49%...	0.10	0.00	0.00	0.36	0.01	0.00	3.00	double		8			28
⊕ num_Account...	0.13% (5)	63.49%...	0.18	0.00	0.00	0.46	0.01	0.00	4.00	double		8			27
⊕ own_closed	0.24% (9)	63.49%...	0.74	0.00	0.00	1.10	0.02	0.00	8.00	double		8			35
⊕ sixty_in_a_year	0.05% (2)	63.49%...	0.08	0.00	0.00	0.28	0.00	0.00	1.00	double		8			40
⊕ sixty_vintage	0.05% (2)	63.49%...	0.01	0.00	0.00	0.11	0.00	0.00	1.00	double		8			43
⊕ sum_of_paym...	8.75% (327)	63.49%...	80.60	62.00	25.00	71.41	1.17	0.00	793.00	double		8			32
⊕ thirty_in_a_year	0.05% (2)	63.49%...	0.15	0.00	0.00	0.35	0.01	0.00	1.00	double		8			39
⊕ thirty_vintage	0.05% (2)	63.49%...	0.03	0.00	0.00	0.17	0.00	0.00	1.00	double		8			42
⊕ Номер вари...	0.01% (1)		19.00	19.00	19.00	0.00	0.00	19.00	19.00	double		8			1

В хорошем качестве



